

# TEORIA DA DECISÃO DE BAYES

**Prof. Dr. Ajalmar Rocha**


**Disciplina: Reconhecimento de Padrões**

Programa de Pós-Graduação em Eng. de Telecomunicações (PPGET)  
Instituto Federal do Ceará (IFCE)

Agosto/2013

- Probabilidades: Visão Geral
- Introdução
- Revisitando o problema de Classificação de Peixe
- Probabilidade a Priori
- Função densidade de probabilidade condicional
- Probabilidade a posteriori
- Regra de Bayes
- Conclusão

## Probabilidades: Visão Geral



**Figure:** Considere duas variáveis aleatórias:  $X$  e  $Y$ . A v.a.  $X$  assume os valores  $\{x_i\}_{i=1}^M$ , enquanto a v.a.  $Y$  assume os valores  $\{y_j\}_{j=1}^L$ . Tendo um total de  $N$  instâncias para ambas as variáveis variáveis, tem-se ainda  $n_{ij}$  instâncias na célula da matriz. Além disto, o número de pontos na coluna  $i$  é  $c_i$ , enquanto o número de pontos na linha  $j$  é  $r_j$ .

# Probabilidades: Visão Geral

- A probabilidade de  $X$  assumir o valor  $x_i$  e  $Y$  assumir o valor  $y_j$  é escrita como  $P(X = x_i, Y = y_j)$ ,  $P(X = x_i \cap Y = y_j)$  ou simplesmente  $P(X, Y)$ .  $P(X, Y)$  é denominada **probabilidade conjunta**.
- A probabilidade conjunta  $P(X, Y)$  pode ser obtida com base no número de pontos que caem na célula  $i, j$ , a saber:

$$P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}. \quad (1)$$

- A probabilidade de  $X$  assumir o valor  $x_i$  (**probabilidade a priori**), ou seja,  $p(X = x_i)$  é dada por

$$P(X = x_i) = \frac{c_i}{N}. \quad (2)$$

# Probabilidades: Visão Geral

- Como o número de pontos na coluna  $i$  é a soma do número de pontos em cada célula daquela coluna, ou seja,  $c_i = \sum_j n_{ij}$  pode-se apresentar a **probabilidade a priori** como segue

$$P(X = x_i) = \sum_{j=1}^L p(X = x_i, Y = y_j) \quad (3)$$

- Ao se considerar apenas pontos para os quais  $X = x_i$ , então a fração de pontos para os quais  $Y = y_j$  é escrita como  $p(Y = y_j | X = x_i)$  e é chamada **probabilidade condicional** de  $Y = y_j$  dado  $X = x_i$ . Esta **probabilidade condicional** pode ser obtida por:

$$p(Y = y_j | X = x_i) = \frac{n_{ij}}{c_i}. \quad (4)$$

# Probabilidades: Visão Geral

- Da Eq. (1) e da Eq. (2), bem como da Eq. (4) pode-se inferir que

$$p(X = x_i, Y = y_i) = \frac{n_{ij}}{N} \quad (5)$$

$$p(X = x_i, Y = y_i) = \frac{n_{ij}}{c_i} \frac{c_i}{N} \quad (6)$$

$$p(X = x_i, Y = y_i) = p(Y = y_j | X = x_i) p(X = x_i) \quad (7)$$

- A equação  $p(X = x_i, Y = y_i) = p(Y = y_j | X = x_i) p(X = x_i)$  é conhecida como **regra do produto**.

- Da Eq. (3) pode-se inferir que

$$p(X = x_i) = \sum_{j=1}^L p(X = x_i, Y = y_j) \quad (8)$$

$$p(X = x_i) = \sum_{j=1}^L p(Y = y_j | X = x_i) p(X = x_i) \quad (9)$$

- A Eq. (9) é conhecida como **regra da soma**.

# Probabilidades: Visão Geral

- Considerando a propriedade de simetria

$$p(X, Y) = p(Y, X), \quad (10)$$

a **regra de Bayes** pode ser obtida da regra do produto

$$p(Y|X)p(X) = p(Y, X) \quad (11)$$

$$p(Y|X)p(X) = p(X|Y)p(Y) \quad (12)$$

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)} \quad (13)$$

combinada com a regra da soma, como segue

$$p(Y|X) = \frac{p(X|Y)p(Y)}{\sum_Y p(X|Y)p(Y)}. \quad (14)$$



# Introdução

- A Teoria de Decisão de Bayes é uma abordagem estatística que quantifica o compromisso entre diversas decisões usando probabilidades e os custos relacionados com tais decisões.
- Primeiramente, será considerado que todas as probabilidades são conhecidas.
- Posteriormente, serão visto casos em que as probabilidades não são completamente conhecidas e, assim, as mesmas devem ser estimadas.

# Revisitando o problema de Classificação de Peixe

- Uma categoria (state of nature) é uma variável aleatória.
- Considere  $W_j$  como um tipo de peixe que foi observado (state of nature, classe) em que
  - $W_j = W_1$  para a classe sea bass; e
  - $W_j = W_2$  para a classe salmon.
  - $P(W_1)$  é a probabilidade a priori de que o próximo peixe seja um sea bass.
  - $P(W_2)$  é a probabilidade a priori de que o próximo peixe seja um salmon.

# Probabilidades a Priori

- Probabilidade a priori reflete nosso conhecimento de como cada tipo de peixe aparecerá na esteira antes de se realmente observar os peixes.
- A probabilidade a priori pode ser entendida como a crença com base em conhecimento prévio de que na esteira ocorrerá sea bass em uma determinada proporção.
- Como se escolhe os valores de  $P(W_1)$  e  $P(W_2)$ ?
  - Defina  $P(W_1) = P(W_2)$  se as classes forem equiprováveis.
  - Pode-se usar diferentes valores para as probabilidades a priori dependendo da área de pesca, estação do ano, dentre outros.
- Assuma que não exista outros tipos de peixe, logo

$$P(W_1) + P(W_2) = 1. \quad (15)$$

# Tomada de Decisão

- Como pode-se tomar uma decisão com base apenas na informação da probabilidade a priori?

$$\text{Classificar como } \begin{cases} W_1, & \text{se } P(W_1) > P(W_2) \\ W_2, & \text{caso contrario.} \end{cases} \quad (16)$$

- Qual é a probabilidade de erro para este processo de tomada de decisão?

# Tomada de Decisão

- Como pode-se tomar uma decisão com base apenas na informação da probabilidade a priori?

$$\textit{Classificar como} \begin{cases} W_1, & \text{se } P(W_1) > P(W_2) \\ W_2, & \text{caso contrario.} \end{cases} \quad (17)$$


- Qual é a probabilidade de erro para este processo de tomada de decisão?

$$P(\textit{error}) = \min \{P(W_1), P(W_2)\} \quad (18)$$

# Função Densidade de Probabilidade Condicional

- Considere-se aprimorar o processo de tomada de decisão usando a característica luminosidade  $x$ .
- Considere-se ainda que  $x$  é uma variável aleatória contínua, tal como o comprimento de um peixe.
- Define-se  $p(x|W_j)$  como a função densidade de probabilidade condicional (*class-conditional probability density*).
- A função densidade de probabilidade condicional  $p(x|W_j)$  é a probabilidade de se ter  $x$  dado que a categoria observada é  $W_j$ , em que  $j = 1, 2$ .
- As funções  $p(x|W_1)$  e  $p(x|W_2)$  descrevem a diferença em termos de comprimento entre as populações de sea bass e salmon.

# Probabilidade Condicional



**Figure:** Tendo  $x$  representando o comprimento de um peixe, as duas curvas permitem verificar a diferença em termos de tamanho das populações sea bass e salmon. A função de densidade de probabilidade condicional é normalizada e, portanto, a área sob a curva para cada uma é 1.0.

# Probabilidade a Posteriori e Regra de Bayes

- Suponha que conhecemos os valores para  $P(W_j)$  e  $p(x|W_j)$  para  $j = 1, 2$ . Além disto, como dito anteriormente considere que  $x$  é o comprimento de um peixe.
- $P(W_j|x)$  é a probabilidade a posteriori, uma função que representa a probabilidade de categorizar um peixe como sendo da classe  $W_j$  para um dado valor de interesse da característica  $x$ .
- Neste contexto, pode-se utilizar a regra de Bayes para converter a probabilidade a priori para a probabilidade a posteriori

$$P(W_j|x) = \frac{p(x|W_j)P(W_j)}{p(x)}, \quad (19)$$

em que  $p(x) = \sum_{j=1}^2 p(x|W_j)P(W_j)$ .



# Probabilidade a Posteriori




Figure: Probabilidades a posteriori para as classes *sea bass* e *salmon*, considerando  $P(W_1) = \frac{2}{3}$  e  $P(W_2) = \frac{1}{3}$ . Para  $x = 14$ ,  $P(W_1|x) = 0.92$  e  $P(W_2|x) = 0.08$ . Para cada  $x$ , a soma das probabilidades a posteriori é 1,0.

# Tomada de Decisão

- A função de densidade condicional  $p(x|W_j)$  é também chamada de função de verossimilhança (*likelihood function*), enquanto  $p(x)$  é chamada de evidência (*evidence*).
- Em termos de nomenclatura tem-se

$$P(W_j|x) = \textit{posteriori} = \frac{\textit{likelihood} \times \textit{priori}}{\textit{evidence}}, \quad (20)$$

- Como pode ser feita uma decisão após a observação de um determinado  $x$ ?

$$\textit{Classificar como} \begin{cases} W_1 & \text{se } P(W_1|x) > P(W_2|x) \\ W_2 & \text{caso contrario.} \end{cases} \quad (21)$$

# Tomada de Decisão

- O processo de tomada de decisão

$$\text{Classificar como } \begin{cases} W_1 & \text{se } P(W_1|x) > P(W_2|x) \\ W_2 & \text{caso contrario.} \end{cases} \quad (22)$$

pode-se reescrito da seguinte maneira

$$\text{Classificar como } \begin{cases} W_1 & \text{se } \frac{P(x|W_1)}{P(x|W_2)} > \frac{P(W_2)}{P(W_1)} \\ W_2 & \text{caso contrario.} \end{cases} \quad (23)$$

- Note que, para cada  $x$ ,  $P(W_1|x) + P(W_2|x) = 1$ .

# Probabilidade de Erro

- Qual é a probabilidade de erro para uma decisão tomada com base na probabilidade a posteriori?

$$P(\text{error}|x) = \begin{cases} P(W_1|x), & \text{se foi decidido } W_2 \\ P(W_2|x), & \text{se foi decidido } W_1 \end{cases} \quad (24)$$


- Qual é a probabilidade média de erro?

$$p(\text{error}) = \int_{-\infty}^{+\infty} p(\text{error}, x) dx = \int_{-\infty}^{+\infty} p(\text{error}|x) p(x) dx \quad (25)$$

- A regra de decisão de Bayes minimiza esse erro uma vez que

$$p(\text{error}|x) = \min \{p(W_1|x), p(W_2|x)\} \quad (26)$$

# Probabilidade de Erro



**Figure:** Exemplo de duas regiões  $R_1$  e  $R_2$  formado por um classificador de Bayes para o caso de duas classes equiprováveis.

## **Classificador de Bayes é ótimo!**

- O classificador de Bayes é ótimo no tocante à minimização da probabilidade de erro de classificação.
- O que aconteceria se houvesse uma movimentação do limiar para outro valor que não  $x_0$  na figura anterior.

## Prova: Minimização da Probabilidade de Erro

- Considere a região  $R_1$  em que se decide em favor de  $W_1$  e  $R_2$  a região em que se decide em favor de  $R_2$ . Um erro é cometido se  $x \in R_1$ , mas pertence verdadeiramente a classe  $W_2$ ; ou se  $x \in R_2$ , mas pertence verdadeiramente a classe  $W_1$ . Assim, a  $P(\text{erro})$  também pode ser expresso por

$$p(\text{erro}) = p(x \in R_2, W_1) + p(x \in R_1, W_2)$$

$$p(\text{erro}) = p(x \in R_2|W_1)p(W_1) + p(x \in R_1|W_2)p(W_2)$$

$$p(\text{erro}) = \int_{R_2} P(x|W_1)p(W_1)dx + \int_{R_1} P(x|W_2)p(W_2)dx$$

$$p(\text{erro}) = p(W_1) \int_{R_2} p(x|W_1)dx + p(W_2) \int_{R_1} p(x|W_2)dx$$

# Probabilidade de Erro

- Usando a regra de Bayes sobre

$$p(\text{erro}) = p(W_1) \int_{R_2} p(x|W_1)dx + p(W_2) \int_{R_1} p(x|W_2)dx$$

tem-se

$$p(\text{erro}) = p(W_1) \int_{R_2} \frac{p(W_1|x)p(x)}{p(W_1)}dx + p(W_2) \int_{R_1} \frac{p(W_2|x)p(x)}{p(W_2)}dx$$

$$p(\text{erro}) = \int_{R_2} p(W_1|x)p(x)dx + \int_{R_1} p(W_2|x)p(x)dx \quad (27)$$

- Do conceito de probabilidade marginal (a priori) e considerando que  $R_1$  e  $R_2$  cobrem todo o espaço, tem-se que

$$\int_{R_1} p(W_1, x)dx + \int_{R_2} p(W_1, x)dx = p(W_1).$$



# Probabilidade de Erro

- Portanto de

$$\int_{R_1} p(W_1, x) dx + \int_{R_2} p(W_1, x) dx = p(W_1)$$

pode-se obter

$$\int_{R_1} p(W_1|x)p(x) dx + \int_{R_2} p(W_1|x)p(x) dx = p(W_1). \quad (28)$$

- Das Eqs. (27) e (28) pode-se inferir que

$$p(\text{erro}) = p(W_1) - \int_{R_1} (p(W_1|x) - p(W_2|x))p(x) dx \quad (29)$$

- Este resultado sugere que a probabilidade de erro é minimizada se  $R_1$  é a região do espaço em que  $p(W_1|x) > p(W_2|x)$ . Resultado similar pode ser obtido para  $R_2$ .

# Teoria da Decisão de Bayes

- Como generalizar para
  - mais de uma característica?
    - substituir a escalar  $x$  pelo vetor de características  $\mathbf{x}$ .
  - mais de duas categorias?
    - apenas uma questão de notação.
  - permitir outras ações além de tomada de decisões?
    - deve-se permitir a possibilidade de rejeição.
  - diferentes riscos no processo de tomada de decisão?
    - definir quão custosa é cada uma das ações.

# Teoria da Decisão de Bayes

Leve em consideração que

- $\{W_1, \dots, W_c\}$  é um conjunto de  $c$  categorias (classes).
- $\{\alpha_1, \dots, \alpha_a\}$  é um conjunto finito de  $a$  possíveis ações.
- $\lambda(\alpha_i|W_j)$  é a perda obtida por tomar uma ação  $\alpha_i$  (tomar uma decisão) quando a categoria é verdadeiramente  $W_j$ .
- $\mathbf{x}$  é um vetor  $d$ -dimensional (i.e.,  $\mathbf{x} \in \mathbb{R}^d$ ) chamada vetor de características.

# Teoria da Decisão de Bayes

Leve em consideração que

- $p(\mathbf{x}|W_j)$  é a função densidade de probabilidade condicional dado que se observou  $W_j$ .
- $P(W_j)$  é a probabilidade a priori, ou seja, a probabilidade relacionada ao conhecimento prévio da classe  $W_j$ .
- A probabilidade a posteriori pode ser computada como segue

$$p(W_j|\mathbf{x}) = \frac{p(\mathbf{x}|W_j)P(W_j)}{p(\mathbf{x})} \quad (30)$$

em que  $p(\mathbf{x}) = \sum_{j=1}^c p(\mathbf{x}|W_j)P(W_j)$

## Risco Condicional (Perda Esperada)

- Suponha que observa-se  $\mathbf{x}$  e toma-se a seguinte ação  $\alpha_i$ .
- Se a categoria é verdadeiramente da classe  $W_j$ , incorre-se em uma perda  $\lambda(\alpha_i|W_j)$ .
- A perda esperada (expectation loss) em relação a tomar a ação  $\alpha_i$  é

$$R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i|W_j)P(W_j|\mathbf{x}) \quad (31)$$

a qual é também chamado de **risco condicional**.

# Classificação com Risco Mínimo

- Um regra de decisão geral  $\alpha(\mathbf{x})$  nos informa que ação deve ser tomada para uma observação  $\mathbf{x}$ , ou seja,  
 $\alpha(\mathbf{x}) \rightarrow \{\alpha_1, \alpha_2 \dots \alpha_a\}$ .
- Deseja-se encontrar a regra de decisão que minimiza o risco geral

$$R = \int R(\alpha(\mathbf{x})|x)p(x)d\mathbf{x}. \quad (32)$$

- A regra de decisão de Bayes minimiza o risco geral pela seleção da ação  $\alpha_i$  de tal maneira que  $R(\alpha_i|x)$  é mínima.
- O risco geral mínimo resultante é chamado de risco de Bayes e é o melhor desempenho que pode ser alcançado.

# Classificação com 2 Categorias (Binária)

- Considere que
  - 1  $\alpha_1$  representa decidir por  $W_1$ .
  - 2  $\alpha_2$  representa decidir por  $W_2$ .
  - 3  $\lambda_{ij} = \lambda(\alpha_i|W_j)$  é o risco de tomar a ação  $\alpha_i$  (ou seja, decidir por  $W_i$ ) quando a categoria é verdadeiramente  $W_j$ .
- Os riscos condicionais podem ser escritas como

$$R(\alpha_1|\mathbf{x}) = \lambda_{11}P(W_1|\mathbf{x}) + \lambda_{12}P(W_2|\mathbf{x})$$

$$R(\alpha_2|\mathbf{x}) = \lambda_{21}P(W_1|\mathbf{x}) + \lambda_{22}P(W_2|\mathbf{x})$$

# Classificação com 2 Categorias (Binária)

- A regra de decisão de risco mínimo é

$$\text{Classificar como } \begin{cases} W_1 & \text{se } R(\alpha_1|\mathbf{x}) < R(\alpha_2|\mathbf{x}) \\ W_2 & \text{caso contrario} \end{cases} \quad (33)$$

- A regra de decisão de risco mínimo também pode ser escrita como

$$\text{Classificar como } \begin{cases} W_1 & \text{se } (\lambda_{21} - \lambda_{12})p(W_1|\mathbf{x}) > (\lambda_{12} - \lambda_{22})p(W_2|\mathbf{x}) \\ W_2 & \text{Caso contrario} \end{cases} \quad (34)$$

- Isto corresponde a decidir  $W_1$  se

$$\frac{p(\mathbf{x}|W_1)}{p(\mathbf{x}|W_2)} > \frac{(\lambda_{12} - \lambda_{22})P(W_2)}{(\lambda_{21} - \lambda_{11})P(W_1)} \quad (35)$$

em que  $(\lambda_{12} - \lambda_{22}) > 0$  e  $(\lambda_{21} - \lambda_{11}) > 0$ . O termo  $\frac{p(\mathbf{x}|W_1)}{p(\mathbf{x}|W_2)}$  é chamado de razão de verossimilhança, além disto o termo  $\frac{(\lambda_{12} - \lambda_{22})P(W_2)}{(\lambda_{21} - \lambda_{11})P(W_1)}$  pode ser visto como um limiar que é independente da observação  $\mathbf{x}$ .



# Classificação com Taxa de Erro Mínima

- Ações são decisão sobre classes ( $\alpha_i$  equivale a decidir por  $W_i$ ).
- Se uma ação  $\alpha_i$  é tomada e a categoria é verdadeiramente  $W_j$ , então a decisão é correta se  $i = j$  e errada if  $i \neq j$ .
- Deseja-se encontrar uma regra de decisão que minimize a probabilidade de erro.

## Classificação com Taxa de Erro Mínima

- Defina uma função de perda zero-um (*zero-one loss function*)

$$\lambda(\alpha_i|W_j) = \begin{cases} 0 & \text{se } i = j, \\ 1 & \text{se } i \neq j, \end{cases} \quad (36)$$

em que, portanto, os erros tem o mesmo custo.

- O risco condicional para este caso se torna

$$\begin{aligned} R(\alpha_i|\mathbf{x}) &= \sum_{j=1}^c \lambda(\alpha_i|W_j)p(W_j|\mathbf{x}) \\ R(\alpha_i|\mathbf{x}) &= \sum_{i \neq j} p(W_j|\mathbf{x}) \\ R(\alpha_i|\mathbf{x}) &= 1 - p(W_i|\mathbf{x}) \end{aligned} \quad (37)$$

# Classificação com Taxa de Erro Mínima

- Minimizar o risco exige a maximização de  $p(W_i|\mathbf{x})$  e resulta em uma regra de decisão de erro mínimo.

*Classificar como  $W_i$  se  $p(W_i|\mathbf{x}) > p(W_j|\mathbf{x}) \quad \forall j \neq i$  (38)*

- O erro resultante do processo de maximização é chamado erro de Bayes e representa o melhor desempenho que se pode alcançar.

## Exemplos de Padrões




Figure:  $\theta_a$  é o limiar para a função de perda zero-um,  $P(W_1) = \frac{2}{3}$  e  $P(W_2) = \frac{1}{3}$ . Se  $(\lambda_{12} > \lambda_{21})$  tem-se limiares maiores, tal como  $\theta_b$ .


# Classificadores, Funções Discriminantes e Superfícies de Decisão

- Há diversas maneiras de representar classificadores de padrões.
- Uma das maneiras mais úteis é através de funções discriminantes  $g_i(\mathbf{x})$ , tal que  $i = 1, 2, \dots, c$ .
- Um classificador associa um vetor de características  $\mathbf{x}$  a uma classe  $W_i$  se

$$g_i(\mathbf{x}) > g_j(\mathbf{x}) \forall j \neq i. \quad (39)$$

- No contexto de funções discriminantes, o classificador é visto como uma rede ou máquina que computa  $c$  funções discriminantes e seleciona a categoria correspondente à função de maior valor de discriminante.

## Exemplos de Padrões



**Figure:** Um classificador de padrões estatístico com  $d$  entradas e  $c$  funções discriminantes  $g_j(\mathbf{x})$ . As setas indicam o fluxo de informações.

# Classificadores, Funções Discriminantes e Superfícies de Decisão

- O classificador de Bayes é naturalmente representado da forma como apresentado na Fig. (38).
- Para o caso geral em que se considera o risco de se tomar uma decisão, representa-se o discriminante por

$$g_i(\mathbf{x}) = -R(\alpha_i|\mathbf{x}), \quad (40)$$

uma vez que a função discriminante de valor máximo corresponderá ao risco condicional mínimo.

- Para o caso da minimização da taxa de erro (probabilidade de erro), o discriminante é representado por

$$g_i(\mathbf{x}) = P(W_i|\mathbf{x}), \quad (41)$$

tal que a função discriminante de valor máximo representa a máxima probabilidade a posteriori (MAP rule).

# Classificadores, Funções Discriminantes e Superfícies de Decisão

- A escolha da função discriminante não é única, uma vez que a multiplicação de todas as funções discriminantes por uma mesma constante positiva, bem como a adição a todas as funções discriminantes de uma mesma constante não influencia na decisão.
- De uma forma geral, se a função  $g_i(\mathbf{x})$  for substituída por  $f(g_i(\mathbf{x}))$ , em que  $f(\cdot)$  é uma função monotonicamente crescente, o resultado não é alterado.
- Isto traz simplificações computacionais interessantes, em particular para o caso da regra MAP, qualquer uma das seguintes escolhas, a saber

$$g_i(\mathbf{x}) = P(W_i|\mathbf{x}) = \frac{p(\mathbf{x}|C_i)p(W_i)}{\sum_{j=1}^c p(\mathbf{x}|C_j)p(W_j)} \quad (42)$$

$$g_i(\mathbf{x}) = p(\mathbf{x}|C_i)p(W_i) \quad (43)$$

$$g_i(\mathbf{x}) = \ln(p(\mathbf{x}|C_i)p(W_i)) \quad (44)$$

$$g_i(\mathbf{x}) = \ln p(\mathbf{x}|C_i) + \ln p(W_i) \quad (45)$$



# Classificadores, Funções Discriminantes e Superfícies de Decisão

- Embora as funções discriminantes possam ser divididas em uma variedade de formas, as regras de decisão são equivalentes.
- O efeito de qualquer regra de decisão é dividir o espaço de características em  $c$  regiões de decisão  $R_1, R_2, \dots, R_c$ . Se  $g_i(\mathbf{x}) > g_j(\mathbf{x}) \forall j \neq i$ , então  $\mathbf{x}$  está em  $R_i$ .
- As regiões são separadas por superfícies de decisão, i.e., as superfícies formadas pelos pontos que pertencem a mais de uma função discriminante (i.e, a interseção entre as superfícies).
- Para o caso binário em que se decide por classificar  $\mathbf{x}$  em  $W_1$ , se  $g_1(\mathbf{x}) > g_2(\mathbf{x})$ ; pode-se, porém, definir uma função discriminante mais simples

$$g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x}) \quad (46)$$

em que se classifica um dado padrão  $\mathbf{x}$  em  $W_1$  se  $g(\mathbf{x}) > 0$ .

OBRIGADO