

DENSIDADE DE PROBABILIDADE GAUSSIANA

Prof. Dr. Ajalmar Rocha

Disciplina: Reconhecimento de Padrões

Programa de Pós-Graduação em Eng. de Telecomunicações (PPGET)
Instituto Federal do Ceará (IFCE)

Agosto/2013

- Introdução
- Densidade Univariada Gaussiana
- Densidade Multivariada Gaussiana
- Matriz de Covariância
- Influência da Matriz de Covariância na Distribuição Normal
- Classificador Bayesiano para Classes com Distribuição Normal

Densidade Univariada Gaussiana

- A função densidade univariada Gaussiana contínua é dada por

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\} \quad (1)$$

em que x pode representar, por exemplo, o atributo de um padrão.

- A função densidade de probabilidade Gaussiana é completamente especificada por dois parâmetros: média μ e variância σ^2 , enquanto σ é denominado desvio padrão.
- Por simplicidade, utiliza-se a abreviação da Eq. (1) por

$$p(x) \sim \mathbf{N}(\mu, \sigma^2), \quad (2)$$

representando a informação de que x é normalmente distribuída com média μ e variância σ^2 .

- Padrões que seguem uma distribuição normal tendem a se agrupar em torno da média μ e com um espalhamento proporcional ao desvio padrão σ .

Densidade de Probabilidade Gaussiana

Densidade Univariada Gaussiana




Figure: Uma função densidade de probabilidade normal tem aproximadamente 95 por cento da sua área na faixa $|x - \mu| \leq 2\sigma$. O pico da função é dado por $p(\mu) = \frac{1}{\sqrt{2\pi}\sigma}$

Densidade Multivariada Gaussiana

- A função densidade multivariada Gaussiana contínua é dada por

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \cdot \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right\} \quad (3)$$

em que $\mathbf{x}$ é um vetor coluna com d componentes, μ é o vetor de médias também com d componentes e Σ é a matriz de covariância de tamanho $d \times d$. Logo, $|\Sigma|$ e Σ^{-1} são o determinante e a inversa da matriz de covariância, respectivamente.

Matriz de Covariância

- A matriz de covariância é dada por

$$\Sigma = \begin{bmatrix} \sigma_{11} = \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1n} \\ \sigma_{21} & \sigma_{22} = \sigma_2^2 & \dots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_{nn} = \sigma_n^2 \end{bmatrix},$$

em que $\sigma_{ij} = \text{cov}(x_i, x_j)$ representa a covariância entre a i -ésima e a j -ésima componentes do vetor $\mathbf{x}$ e é calculado por

$$\sigma_{ij} = \sum_{k=1}^N \frac{(x_{ik} - \bar{x}_i)(x_{jk} - \bar{x}_j)}{N - 1} \quad (4)$$

- A variância σ_i^2 é um caso particular de σ_{ij} em que i e j são iguais. Situação que ocorre na diagonal principal da matriz Σ .

Influência da Matriz de Covariância na Gaussiana




Figure: Gaussiana bidimensional com matriz de covariância diagonal com $\sigma_{11} = \sigma_{22} = 3$ (ou seja, $\sigma_{12} = \sigma_{21} = 0$). O gráfico tem simetria esférica não demonstrando preferência em termos de direção.

Influência da Matriz de Covariância na Gaussiana




Figure: Gaussiana bidimensional com matriz de covariância diagonal com $\sigma_{11} = 15 \gg \sigma_{22} = 3$ e com $\sigma_{12} = \sigma_{21} = 0$.

Influência da Matriz de Covariância na Gaussiana




Figure: Gaussiana bidimensional com matriz de covariância diagonal com $\sigma_{11} = 3 \gg \sigma_{22} = 15$ e com $\sigma_{12} = \sigma_{21} = 0$.

Influência da Matriz de Covariância na Gaussiana




Figure: Gaussiana bidimensional com matriz de covariância com $\sigma_{11} = 15$, $\sigma_{22} = 3$ e com $\sigma_{12} = \sigma_{21} = 6$.

Classificador Bayesiano para Distribuição Normal

- Considere o classificador Bayesiano ótimo quando a função de verossimilhança $p(\mathbf{x}|W_i)$, tal que $i = 1, 2, \dots, c$ é uma gaussiana multivariada a qual descreve a distribuição dos dados para cada uma das classes.
- Em virtude da forma exponencial das distribuições envolvidas é preferível se trabalhar com as seguintes funções discriminantes, os quais envolvem a função logaritmo natural ($\ln$), a saber:

$$\begin{aligned}g_i(\mathbf{x}) &= \ln \left(\frac{p(\mathbf{x}|W_i)p(W_i)}{p(\mathbf{x})} \right) \\g_i(\mathbf{x}) &= \ln(p(\mathbf{x}|W_i)p(W_i)) \\g_i(\mathbf{x}) &= \ln p(\mathbf{x}|W_i) + \ln p(W_i)\end{aligned}\tag{5}$$

Classificador Bayesiano para Distribuição Normal

- Logo, pode-se expandir a Eq. (5) para:

$$\begin{aligned}g_i(\mathbf{x}) &= \ln \left(\frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{-\frac{1}{2}}} \cdot \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right\} \right) + \ln p(W_i) \\g_i(\mathbf{x}) &= -\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) + \ln p(W_i) + \overbrace{\left[-\frac{1}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| \right]}^{c_i} \\g_i(\mathbf{x}) &= -\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) + \ln p(W_i) + c_i\end{aligned}\quad (6)$$

- Expandindo a Eq. (6), pode-se obter

$$g_i(\mathbf{x}) = -\frac{1}{2} \mathbf{x}^T \Sigma_i^{-1} \mathbf{x} + \frac{1}{2} \mathbf{x}^T \Sigma_i^{-1} \mu_i - \frac{1}{2} \mu_i^T \Sigma_i^{-1} \mu_i + \frac{1}{2} \mu_i^T \Sigma_i^{-1} \mathbf{x} + \ln p(W_i) + c_i \quad (7)$$

Classificador Bayesiano para Distribuição Normal

- De uma forma geral, este discriminante é não linear e, por consequência, a superfície de decisão também é não linear, tendo forma quadrática.
- Tome por exemplo o caso em que $n = 2$ e assumamos que

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}, = \begin{bmatrix} \sigma_i^2 & 0 \\ 0 & \sigma_i^2 \end{bmatrix},$$

- Logo, da equação

$$g_i(\mathbf{x}) = -\frac{1}{2}\mathbf{x}^T \Sigma_i^{-1} \mathbf{x} + \frac{1}{2}\mathbf{x}^T \Sigma_i^{-1} \mu_i - \frac{1}{2}\mu_i^T \Sigma_i^{-1} \mu_i + \frac{1}{2}\mu_i^T \Sigma_i^{-1} \mathbf{x} + \ln p(W_i) + c_i$$

obtem-se

$$g_i(x_1, x_2) = -\frac{1}{2\sigma_i^2}(x_1^2 + x_2^2) + \frac{1}{\sigma_i^2}(\mu_{i1}x_1 + \mu_{i2}x_2) - \frac{1}{2\sigma_i^2}(\mu_{i1}^2 + \mu_{i2}^2) + \ln p(W_i) + c_i$$

Classificador Bayesiano para Distribuição Normal

- Uma vez que as funções discriminantes $g_i(\mathbf{x})$ e $g_j(\mathbf{x})$ na equação $g_i(\mathbf{x}) - g_j(\mathbf{x}) = 0$ são quadráticas (i.e., elipses, parábolas, hiperboles, par de linhas).
- Tem-se que o classificador Bayesiano também é descrito por uma quadrática em termos da superfície de decisão.
- Para $n > 2$, a superfície de decisão são hiperquadráticas (elipsóides, parabolóides, hiperbolóides, pares de hiperplanos).

Exemplo 1: Classificador Bayesiano para Distribuição Normal

- Considere o discriminante $g_1(\mathbf{x})$ com a seguinte matriz de covariância Σ_1

$$\Sigma_1 = \begin{bmatrix} 0.3 & 0.0 \\ 0.0 & 0.35 \end{bmatrix},$$

- Considere ainda o discriminante $g_2(\mathbf{x})$ com a seguinte matriz de covariância Σ_2

$$\Sigma_2 = \begin{bmatrix} 1.2 & 0.0 \\ 0.0 & 1.85 \end{bmatrix},$$

Exemplo 1: Classificador Bayesiano para Distribuição Normal




Figure: Discriminantes correspondentes à $p(W_1) = p(W_2)$, $\mu_1 = [0 \ 0]^T$ e $\mu_2 = [4 \ 0]^T$, para as matrizes de covariância mostradas no slide anterior.

Exemplo 1: Classificador Bayesiano para Distribuição Normal




Figure: Superfície (elipse) correspondente à $p(W_1) = p(W_2)$, $\mu_1 = [0 \ 0]^T$ e $\mu_2 = [4 \ 0]^T$, para as matrizes de covariância mostradas no slide anterior.

Exemplo 2: Classificador Bayesiano para Distribuição Normal

- Similarmente, considere o discriminante $g_1(\mathbf{x})$ com a seguinte matriz de covariância Σ_1

$$\Sigma_1 = \begin{bmatrix} 0.1 & 0.0 \\ 0.0 & 0.75 \end{bmatrix},$$

- Considere ainda o discriminante $g_2(\mathbf{x})$ com a seguinte matriz de covariância Σ_2

$$\Sigma_2 = \begin{bmatrix} 0.75 & 0.0 \\ 0.0 & 0.1 \end{bmatrix},$$

Exemplo 2: Classificador Bayesiano para Distribuição Normal




Figure: Discriminantes correspondentes à $p(W_1) = p(W_2)$, $\mu_1 = [0 \ 0]^T$ e $\mu_2 = [4 \ 0]^T$, para as matrizes de covariância mostradas no slide anterior.

Exemplo 2: Classificador Bayesiano para Distribuição Normal




Figure: Superfície (hipérbole) correspondente à $p(W_1) = p(W_2)$, $\mu_1 = [0 \ 0]^T$ e $\mu_2 = [3.2 \ 0]^T$, para as matrizes de covariância mostradas no slide anterior.

Superfície de Decisão Linear para $\Sigma_i = \Sigma$

- A única contribuição quadrática em

$$g_i(\mathbf{x}) = -\frac{1}{2}\mathbf{x}^T \Sigma_i^{-1} \mathbf{x} + \frac{1}{2}\mathbf{x}^T \Sigma_i^{-1} \mu_i - \frac{1}{2}\mu_i^T \Sigma_i^{-1} \mu_i + \frac{1}{2}\mu_i^T \Sigma_i^{-1} \mathbf{x} + \ln p(W_i) + c_i$$

surge do termo $\mathbf{x}^T \Sigma_i^{-1} \mathbf{x}$.

- Caso se assuma que a matriz de covariância é a mesma para todas as classes, i.e, $\Sigma_i = \Sigma$, então o termo quadrático será o mesmo para todas as funções discriminantes.
- Nestas condições, o termo é cancelado na equação da superfície de decisão $g_1(\mathbf{x}) - g_2(\mathbf{x}) = 0$. O mesmo ocorre para a constante c_i .
- Neste contexto, o discriminante pode ser redefinido para

$$g_i(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T \Sigma_i^{-1} \mu_i - \frac{1}{2}\mu_i^T \Sigma_i^{-1} \mu_i + \frac{1}{2}\mu_i^T \Sigma_i^{-1} \mathbf{x} + \ln p(W_i) \quad (8)$$

em que se define $\mathbf{w}_i = \Sigma_i^{-1} \mu_i$ e $w_{i0} = \ln p(W_i) - \frac{1}{2}\mu_i^T \Sigma_i^{-1} \mu_i$. Logo, tem-se

$$g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0} \quad (9)$$

Classificador Bayesiano

Matriz de Covariância Diagonal com Elementos Iguais

- Assuma que as características individuais são mutuamente descorrelacionadas e de mesma variância.
- Nesta situação, $\Sigma = \sigma^2 I$, em que I é a matriz identidade n -dimensional.
- Assim, a partir da equação

$$g_i(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \Sigma_i^{-1} \mu_i - \frac{1}{2} \mu_i^T \Sigma_i^{-1} \mu_i + \frac{1}{2} \mu_i^T \Sigma_i^{-1} \mathbf{x} + \ln p(W_i)$$

tem-se

$$g_i(\mathbf{x}) = \frac{1}{\sigma^2} \mu_i^T \mathbf{x} + w_{i0}. \quad (10)$$

Classificador Bayesiano

Matriz de Covariância Diagonal com Elementos Iguais

- A superfície de decisão (hiperplano) correspondente pode ser escrita como segue

$$g_{ij}(\mathbf{x}) \equiv g_i(\mathbf{x}) - g_j(\mathbf{x}) = \mathbf{w}^T(\mathbf{x} - \mathbf{x}_0) = 0 \quad (11)$$

em que

$$\mathbf{w} = \mu_i - \mu_j \quad (12)$$

e

$$\mathbf{x}_0 = \frac{1}{2}(\mu_i + \mu_j) - \sigma^2 \ln \left(\frac{p(W_i)}{p(W_j)} \right) \frac{\mu_i - \mu_j}{\|\mu_i - \mu_j\|^2} \quad (13)$$

em que $\|\mathbf{x}\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$ denota a norma euclidiana do vetor $\mathbf{x}$ e x_i é a i -ésima componente do vetor $\mathbf{x}$.

Classificador Bayesiano

Matriz de Covariância Diagonal com Elementos Iguais

- A superfície de decisão é um hiperplano que passa pelo ponto $\mathbf{x}_0$.
- No caso em que as classes são equiprováveis (i.e., $p(W_i) = p(W_j)$), o ponto $\mathbf{x}_0 = \frac{1}{2}(\mu_i + \mu_j)$. Logo, o hiperplano passa no ponto médio do segmento de reta que liga as médias μ_i e μ_j .
- Quando as probabilidades a priori são diferentes, o hiperplano vai estar mais distante da média daquela classe com maior probabilidade. Ou seja, se $p(W_i) > p(W_j)$, então o hiperplano estará mais próximo da média μ_j da classe W_j e mais distante da média μ_i da classe W_i . O oposto é verificado para o caso em que $p(W_i) < p(W_j)$.
- Em todos os casos ($p(W_i) = p(W_j)$, $p(W_i) > p(W_j)$ e $p(W_i) < p(W_j)$), a superfície de decisão é ortogonal ao vetor $\mu_i - \mu_j$.

Classificador Bayesiano

Matriz de Covariância Diagonal com Elementos Iguais




Figure: Superfície de decisão para vetores distribuídos normalmente com $\Sigma = \sigma^2 I$. A reta preta corresponde ao caso em que $p(W_i) = p(W_j)$. Enquanto a reta azul corresponde ao caso em que $p(W_i) < p(W_j)$.

Classificador Bayesiano

Matriz de Covariância Diagonal com Elementos Iguais

- Vale destacar que se a variância σ^2 possuir um valor pequeno em relação à norma do vetor $\mu_i - \mu_j$ (i.e., $\|\mu_i - \mu_j\|$), então a localização da superfície de decisão é mais insensível à diferença entre as probabilidades a priori.
- Isto é esperado, uma vez que uma variância pequena indica que os vetores aleatórios são agrupados em um raio pequeno ao redor de sua média.
- Logo, um pequeno deslocamento na superfície de decisão tem um pequeno efeito no resultado.

Classificador Bayesiano

Matriz de Covariância Diagonal com Elementos Iguais




Figure: Superfície de decisão para classes compactas (pequena variância) e não compactas (variância elevada). Diferenças entre as probabilidades a priori afetam menos as classes compactas do que as não-compactas.

Classificador Bayesiano

Matriz de Covariância não-diagonal

- Os argumentos utilizados anteriormente podem ser utilizados de forma similar para a obtenção da superfície de decisão para o classificador Bayesiano com matriz de covariância não-diagonal, a saber:

$$g_{ij}(\mathbf{x}) \equiv g_i(\mathbf{x}) - g_j(\mathbf{x}) = \mathbf{w}^T(\mathbf{x} - \mathbf{x}_0) = 0 \quad (14)$$

em que

$$\mathbf{w} = \Sigma^{-1}(\mu_i - \mu_j) \quad (15)$$

e

$$\mathbf{x}_0 = \frac{1}{2}(\mu_i + \mu_j) - \ln \left(\frac{p(W_i)}{p(W_j)} \right) \frac{\mu_i - \mu_j}{\|\mu_i - \mu_j\|_{\Sigma^{-1}}^2} \quad (16)$$

em que $\|\mathbf{x}\|_{\Sigma^{-1}} \equiv (\mathbf{x}^T \Sigma^{-1} \mathbf{x})^{\frac{1}{2}}$ denota a distância de Mahalanobis do vetor $\mathbf{x}$.

- A superfície de decisão, nesta situação, é ortonormal a transformação linear de $\mu_i - \mu_j$ dada por $\Sigma^{-1}(\mu_i - \mu_j)$.

Classificadores de Distância Mínima

- De um outro ponto de vista, considere a seguinte simplificação para classes equiprováveis

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i) + \ln p(W_i) + c_i$$

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i)$$

em que a constante c_i é negligenciada.

- Vamos considerar duas situações. A primeira situação para $\Sigma = \sigma^2 I$ e a segunda para Σ não-diagonal.

Classificadores de Distância Mínima

- Avalie o discriminante $g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i)$ para
 - 1 $\Sigma = \sigma^2 I$: nesta situação maximizar o discriminante $g_i(\mathbf{x})$ corresponde a minimizar a distância euclidiana

$$d_\epsilon = \|\mathbf{x} - \mu\| = \left((\mathbf{x} - \mu)^T (\mathbf{x} - \mu) \right)^{\frac{1}{2}}. \quad (17)$$

Esse classificador, neste curso, também foi denominando de Distância Mínima ao Centróide.

- 2 Σ não-diagonal : nesta situação maximizar o discriminante $g_i(\mathbf{x})$ equivale a minimizar a norma Σ^{-1} , conhecida como distância de Mahalanobis, a saber:

$$d_m = \left((\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right)^{\frac{1}{2}}. \quad (18)$$

Exemplo: Classificadores de Distância Mínima

Para um problema binário

- Em uma tarefa de classificação, os vetores de características são gerados por duas distribuições normais (gaussianas) com mesma matriz de covariância Σ , dada por

$$\Sigma = \begin{bmatrix} 1.1 & 0.3 \\ 0.3 & 1.9 \end{bmatrix},$$

- A média dos vetores de características para a classe W_1 é $\mu_1 = [0 \ 0]^T$, enquanto a média para a classe W_2 é $\mu_2 = [3 \ 3]^T$.
- Como classificar um dado vetor, tal como $\mathbf{x} = [1.0 \ 2.2]^T$, com base nos vetores de média?

Exemplo: Classificadores de Distância Mínima

Para um problema binário

- Classificar o vetor de acordo com o classificador bayesiano. Isto requer computar a distância de Mahalanobis d_m a partir dos dois vetores de média.
- Para μ_1 tem-se

$$d_m^2(\mathbf{x}, \mu_1) = (\mathbf{x} - \mu_1)^T \Sigma^{-1} (\mathbf{x} - \mu_1)$$

$$d_m^2(\mathbf{x}, \mu_1) = \begin{bmatrix} 1.0 & 2.2 \end{bmatrix} \begin{bmatrix} 0.95 & -0.15 \\ -0.15 & 0.55 \end{bmatrix} \begin{bmatrix} 1.0 \\ 2.2 \end{bmatrix} = 2.952$$

- Similarmente, para μ_2 tem-se

$$d_m^2(\mathbf{x}, \mu_2) = (\mathbf{x} - \mu_2)^T \Sigma^{-1} (\mathbf{x} - \mu_2)$$

$$d_m^2(\mathbf{x}, \mu_2) = \begin{bmatrix} -2.0 & -0.8 \end{bmatrix} \begin{bmatrix} 0.95 & -0.15 \\ -0.15 & 0.55 \end{bmatrix} \begin{bmatrix} -2.0 \\ -0.8 \end{bmatrix} = 3.672$$

- Logo, o vetor pertence a classe W_1 . Porém, caso fosse levado em conta a distância euclidiana o vetor seria dito como pertencente a classe W_2 .

OBRIGADO