

ESTIMAÇÃO DE MÁXIMA VEROSSIMILHANÇA

Prof. Dr. Ajalmar Rocha

Disciplina: Reconhecimento de Padrões

Programa de Pós-Graduação em Eng. de Telecomunicações (PPGET)
Instituto Federal do Ceará (IFCE)

Agosto/2013

- Introdução
- Princípio Geral
- Estimação de Máxima Verossimilhança
- Exemplo: Estimação de Máxima Verossimilhança para Gaussiana

Introdução

- Até agora, trabalhou-se com o projeto de um classificador ótimo considerando-se que as probabilidades a priori e condicional fossem conhecidas.
- Infelizmente, o conhecimento da estrutura probabilística do problema é muito raro, senão impossível.
- Em geral, se tem um conhecimento vago sobre esta estrutura probabilística, junto com um conjunto de padrões (**conjunto de treinamento**) que se supõe ser representativo do conjunto de dados.
- O problema, portanto, é encontrar uma maneira de usar esta informação para projetar um classificador.

Introdução

- Um abordagem possível é usar o conjunto de dados para estimar as probabilidades a priori e as funções densidades de probabilidade desconhecidas e, então, usar estas estimativas como se eles fossem os valores reais.
- Em um problema de classificação de padrões, a estimativa da probabilidade a priori não apresenta-se como um problema. No entanto, não se pode dizer o mesmo para a estimativa das probabilidades condicionais.
- O número de padrões sempre parece ser muito pequeno, bem como se tem problemas quando a dimensionalidade do padrão é alta.
- Entretanto, se o conhecimento do problema permitir a parametrização da função densidade de probabilidade, então a severidade destes problemas pode ser reduzida significativamente uma vez que sabe-se previamente o número de parâmetros.
- E assim, ao invés de se ter de estimar uma função desconhecida $p(\mathbf{x}|W_i)$, tem-se apenas que estimar os parâmetros μ e Σ_i .

Estimação de Máxima Verossimilhança

- O problema de estimação paramétrica é clássico em estatística.
- Uma das formas de abordar este problema é através da estimação de máxima verossimilhança (Maximum Likelihood Estimation - ML Estimation). Estimação bayesiana também é uma opção.
- Na estimação de ML os parâmetros são vistos como quantidades cujos valores são fixos mas desconhecidos.
- Os métodos de estimação de ML apresentam-se atrativos por algumas razões:
 - 1 Eles possuem boa convergência quando o número de padrões aumenta. Ou seja, as estimativas se aproximam bastante do valor real (senão são iguais).
 - 2 Estimação de ML apresentam-se mais simples que métodos alternativos (Estimação Bayesiana e outras).

Princípio Geral

- Suponha que o conjunto de dados é separado de acordo com a classe.
- Logo, tem-se c conjuntos de dados $\mathbb{D}_1, \mathbb{D}_2 \dots \mathbb{D}_c$.
- Cada conjunto $\mathbb{D}_i$ é constituído de padrões que são independentes entre si e é regido pela lei de probabilidade $p(\mathbf{x}|W_i)$.
- Diz-se que os padrões são variáveis aleatórias independentes e identicamente distribuídos.
- Além disto, assume-se que $p(\mathbf{x}|W_i)$ tem uma forma paramétrica conhecida e é determinado unicamente pelo vetor de parâmetros θ_j .
- Por exemplo, pode-se ter $p(\mathbf{x}|W_i) \sim N(\mu_i, \Sigma_i)$, sendo μ_i e Σ_i componentes do vetor θ_j .

Princípio Geral

- Pode-se mostrar explicitamente a dependência de $p(\mathbf{x}|W_i)$ de θ_j apresentando-se $p(\mathbf{x}|W_i)$ como $p(\mathbf{x}|W_i, \theta_j)$.
- O objetivo é da estimação de ML usar a informação dos padrões para estimar os vetores de parâmetros desconhecidos $\theta_1, \theta_2 \dots \theta_c$ associado com cada categoria.
- Para simplificar o problema, considera-se que os padrões pertencentes ao conjunto $\mathbb{D}_j$ não influenciam a obtenção de θ_i se $i \neq j$; ou seja, assume-se que os parâmetros para as diferentes classes são funcionalmente independentes.
- Estas suposições permitem que se trabalhe com cada classe separadamente e a simplificação da notação uma vez que ocorrerá apenas informação de uma única classe.

Estimação de Máxima Verossimilhança

- Assumindo que $\mathbb{D}_i$ contém n padrões e considerando as suposições apresentadas anteriormente, dentre elas que os padrões são v.a. independentes e identicamente distribuídas, tem-se que


$$p(\mathbb{D}|\theta_i) = p(\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n|\theta_i) = \prod_{k=1}^n p(\mathbf{x}_k|W_i\theta_i) \quad (1)$$

- Na Eq. (1), $p(\mathbb{D}|\theta_i)$ é a função de verossimilhança de θ_i em relação à $\mathbb{D}$.
- A estimativa de máxima verossimilhança de θ_i é, por definição, o valor ótimo $\hat{\theta}_i$ que maximiza $p(\mathbb{D}|\theta_i)$, ou seja

$$\hat{\theta}_i = \arg \max_{\theta_i} \{p(\mathbb{D}|\theta_i)\} . \quad (2)$$

- Intuitivamente, esta estimativa corresponde ao valor de θ_i que melhor se ajusta aos padrões de treinamento observados.

Estimação de Máxima Verossimilhança



Estimação de Máxima Verossimilhança

- A primeira figura apresenta pontos em uma dimensão descritos por uma distribuição gaussiana a partir de uma variância particular (fixa) com média desconhecida (variável).
- A segunda figura apresenta a função de ML como uma função da média. O ponto $\hat{\theta}_i$ que maximiza é apresentado.
- A terceira figura também apresenta o ponto $\hat{\theta}_i$ que maximiza o logaritmo da função de verossimilhança. Verifique que, como esperado, os pontos são coincidentes na segunda e na terceira figuras.

Estimação de Máxima Verossimilhança

- É mais fácil trabalhar com logaritmo da função de verossimilhança do que com a própria função como apresentada na Eq. (1), tal como

$$\begin{aligned}l(\theta_i) = \ln p(\mathbb{D}|\theta_i) &= \ln \left\{ \prod_{k=1}^n p(\mathbf{x}_k | W_i \theta_i) \right\} \\l(\theta_i) &= \sum_{k=1}^n \ln p(\mathbf{x}_k | W_i \theta_i)\end{aligned}\tag{3}$$

em que $l(\theta_i)$ depende de $\mathbb{D}$ de forma implícita.

- Uma vez que o logaritmo é monotonicamente crescente, o valor $\hat{\theta}_i$ que maximiza a função de verossimilhança também maximiza o logaritmo desta função.
- Se a função $p(\mathbb{D}|\theta_i)$ é uma função diferenciável em θ então $\hat{\theta}_i$ pode ser obtida pelos métodos padrões de cálculo diferencial.

Estimação de Máxima Verossimilhança

- Reescrevendo a estimativa de máxima verossimilhança de θ_i em termos da maximização do logaritmo da função de verossimilhança $l(\theta_i)$, tem-se

$$\hat{\theta}_i = \arg \max_{\theta_i} \{l(\theta_i)\} . \quad (4)$$

- Uma forma de obter o valor máximo para $\hat{\theta}_i$ consiste em obter o gradiente (vetor de derivadas parciais) do logaritmo da função de verossimilhança ∇_{θ_i} , a saber

$$\nabla_{\theta_i} l(\theta_i) = \begin{bmatrix} \frac{\partial l(\theta_i)}{\partial \theta_1} \\ \frac{\partial l(\theta_i)}{\partial \theta_2} \\ \vdots \\ \frac{\partial l(\theta_i)}{\partial \theta_p} \end{bmatrix} ,$$

em que p representa o número de parâmetros da função densidade de probabilidade que se assumiu como descrevendo os dados.

Estimação de Máxima Verossimilhança

- Uma vez que se deseja o ponto de máximo de θ_i), o conjunto de condições necessárias para obtenção da estimativa de $\hat{\theta}_i$ pode ser obtida do conjunto de p equações de

$$\nabla_{\theta_i} l(\theta_i) = \mathbf{0}. \quad (5)$$

Exemplo: Estimação de ML para Gaussiana Unidimensional

- A função densidade univariada Gaussiana contínua para a v.a x_k é dada por

$$p(x_k | W_i, \theta_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \cdot \exp \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \quad (6)$$

$$p(x_k | W_i, [\mu_i \ \sigma_i]) = \frac{1}{\sqrt{2\pi}\sigma_i} \cdot \exp \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \quad (7)$$

- A função de máxima verossimilhança com base na Eq. (7) é dada por

$$p(\mathbb{D} | W_i, [\mu_i \ \sigma_i]) = \prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma_i} \cdot \exp \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \quad (8)$$

Exemplo: Estimação de ML para Gaussiana Unidimensional

- Em termos de logaritmo da função de verossimilhança tem-se

$$\begin{aligned}l(\theta_i) &= p(\mathbb{D} | W_i, \theta_i) \\l(\mu_i, \sigma_i) &= p(\mathbb{D} | W_i, [\mu_i \ \sigma_i]) \\l(\mu_i, \sigma_i) &= \ln \left\{ \prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma_i} \cdot \exp \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right\} \\l(\mu_i, \sigma_i) &= \sum_{k=1}^n \ln \left\{ \frac{1}{\sqrt{2\pi}\sigma_i} \cdot \exp \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right\} \quad (9)\end{aligned}$$

- Uma vez que se deseja o ponto de máximo de θ_i , o conjunto de condições necessárias para obtenção da estimativa de $\hat{\theta}_i$ pode ser obtida do conjunto de p equações de

$$\nabla_{\theta_i} l(\theta_i) = \nabla_{\theta_i} l(\mu_i, \sigma_i) = \mathbf{0}. \quad (10)$$

Exemplo: Estimação de ML para Gaussiana Unidimensional

- Assim, o gradiente $\nabla_{\theta_i} l(\mu_i, \sigma_i)$ para um ponto ótimo (possivelmente, o ponto de máximo) é dado por

$$\nabla_{\theta_i} l(\mu_i, \sigma_i) = \begin{bmatrix} \frac{\partial l(\mu_i, \sigma_i)}{\partial \mu_i} \\ \frac{\partial l(\mu_i, \sigma_i)}{\partial \sigma_i} \end{bmatrix} = \mathbf{0},$$

Exercício

- Simplifique a equação

$$l(\mu_i, \sigma_i) = \sum_{k=1}^n \ln \left\{ \frac{1}{\sqrt{2\pi}\sigma_i} \cdot \exp \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right\} \quad (11)$$

para

$$l(\mu_i, \sigma_i) = -\frac{n}{2} \ln(2\pi) - n \ln(\sigma_i) - \frac{1}{2\sigma_i^2} \sum_{k=1}^n (x_k - \mu_i)^2 \quad (12)$$

Solução 1/3

- Faça o seguinte

$$l(\mu_i, \sigma_i) = \sum_{k=1}^n \left[\ln \left\{ \frac{1}{\sqrt{2\pi}\sigma_i} \cdot \exp \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right\} \right]$$

$$l(\mu_i, \sigma_i) = \sum_{k=1}^n \left[\ln \left\{ \frac{1}{\sqrt{2\pi}\sigma_i} \right\} + \ln \exp \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right]$$

$$l(\mu_i, \sigma_i) = \sum_{k=1}^n \left[\ln \left\{ \frac{1}{\sqrt{2\pi}\sigma_i} \right\} + \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right]$$

$$l(\mu_i, \sigma_i) = \sum_{k=1}^n \left[\left\{ \ln 1 - \ln \sqrt{2\pi}\sigma_i \right\} + \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right]$$

$$l(\mu_i, \sigma_i) = \sum_{k=1}^n \left[\left\{ \ln e^0 - \ln \sqrt{2\pi}\sigma_i \right\} + \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right]$$

$$l(\mu_i, \sigma_i) = \sum_{k=1}^n \left[\left\{ 0 \cdot \ln e - \ln \sqrt{2\pi}\sigma_i \right\} + \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right]$$

Solução 2/3

• Logo

$$l(\mu_i, \sigma_i) = \sum_{k=1}^n \left[\left\{ 0 - \ln \sqrt{2\pi} \sigma_i \right\} + \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right]$$

$$l(\mu_i, \sigma_i) = \sum_{k=1}^n \left[\left\{ -\ln \sqrt{2\pi} \sigma_i \right\} + \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\} \right]$$

$$l(\mu_i, \sigma_i) = -\sum_{k=1}^n \left\{ \ln \sqrt{2\pi} \sigma_i \right\} + \sum_{k=1}^n \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\}$$

Como $\ln(a.b) = \ln a + \ln b$ então

$$l(\mu_i, \sigma_i) = -\ln \left(\sqrt{2\pi} \sigma_i \right)^n + \sum_{k=1}^n \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\}$$

$$l(\mu_i, \sigma_i) = -\ln \left\{ \left(\sqrt{2\pi} \right)^n (\sigma_i)^n \right\} - \ln (\sigma_i)^n + \sum_{k=1}^n \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\}$$

• Então

$$l(\mu_i, \sigma_i) = -\ln(2\pi)^{\frac{n}{2}} - \ln(\sigma_i)^n + \sum_{k=1}^n \left\{ -\frac{(x_k - \mu_i)^2}{2\sigma_i^2} \right\}$$

Por fim, tem-se que

$$l(\mu_i, \sigma_i) = -\frac{n}{2} \ln(2\pi) - n \ln(\sigma_i) - \frac{1}{2\sigma_i^2} \sum_{k=1}^n \{(x_k - \mu_i)^2\} \quad (13)$$

Exemplo: Estimação de ML para Gaussiana Unidimensional

Votando para a obtenção do valor de $\hat{\theta}_i$

- Lembrando que

$$\begin{bmatrix} \frac{\partial l(\mu_i, \sigma_i)}{\partial \mu_i} \\ \frac{\partial l(\mu_i, \sigma_i)}{\partial \sigma_i} \end{bmatrix} = \mathbf{0},$$

e

$$l(\mu_i, \sigma_i) = -\frac{n}{2} \ln(2\pi) - n \ln(\sigma_i) - \frac{1}{2\sigma_i^2} \sum_{k=1}^n \{(x_k - \mu_i)^2\}$$

logo

$$\frac{\partial l(\mu_i, \sigma_i)}{\partial \mu_i} = \frac{\partial}{\partial \mu_i} \left\{ -\frac{n}{2} \ln(2\pi) - n \ln(\sigma_i) - \frac{1}{2\sigma_i^2} \sum_{k=1}^n \{(x_k - \mu_i)^2\} \right\}$$

$$\frac{\partial l(\mu_i, \sigma_i)}{\partial \sigma_i} = \frac{\partial}{\partial \sigma_i} \left\{ -\frac{n}{2} \ln(2\pi) - n \ln(\sigma_i) - \frac{1}{2\sigma_i^2} \sum_{k=1}^n \{(x_k - \mu_i)^2\} \right\}$$

Exercício

- Obtenha as derivadas

$$\frac{\partial l(\mu_i, \sigma_i)}{\partial \mu_i} = ? \quad (14)$$

e

$$\frac{\partial l(\mu_i, \sigma_i)}{\partial \sigma_i} = ? \quad (15)$$

Solução

- A primeira derivada equivale à

$$\frac{\partial l(\mu_i, \sigma_i)}{\partial \mu_i} = \frac{1}{\sigma_i^2} \sum_{k=1}^n (x_k - \mu_i) \quad (16)$$

enquanto a segunda equivale à

$$\frac{\partial l(\mu_i, \sigma_i)}{\partial \sigma_i} = -\frac{n}{\sigma_i} + \sigma_i^{-3} \sum_{k=1}^n (x_k - \mu_i)^2 \quad (17)$$

Igualando ambas as derivadas a zero obtem-se para μ e σ_i^2

$$\begin{aligned} \mu_i &= \frac{1}{n} \sum_{k=1}^n x_k \\ \sigma_i^2 &= \frac{1}{n} \sum_{k=1}^n (x_k - \mu_i)^2 \end{aligned}$$

OBRIGADO