


Tarefa de Casa

14/04

Aluna: Raquel Maciel Coelho de Sousa



Dados os pontos $\{x_1, x_2, \dots, x_n\}$ que são independentes identicamente distribuídos representados por X extraídas de uma distribuição normal (Gaussiana) com média μ e variância σ^2 cuja função de densidade de probabilidade é dada por:

$$P(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Demonstrar média e variância amostral com a maximização da probabilidade.

Por X ser um conjunto de pontos IID

$$\Rightarrow P(A, B) = P(A) \cdot P(B)$$

então

$$P(x_1, \dots, x_n | \mu, \sigma^2) = \prod_{i=1}^n P(x_i | \mu, \sigma^2)$$

Trabalhar com o produto de exponenciais é extremamente trabalhoso mas pode ser facilitado ao usar o artifício da função $\ln$, que é monotonicamente crescente, e como nosso interesse é maximizar a função isso não será problema pois o valor que maximiza nossa função também irá maximizar $\ln(\text{função})$.

Vamos dar um nome de F para nossa função.

$$F(\mu, \sigma^2) = \prod_{i=1}^n P(x_i | \mu, \sigma^2)$$

$$\Theta = (\mu, \sigma^2)$$

A aplicação do $\ln$ preserva o ponto crítico (maximização):

$$\frac{d \ln(F(\theta))}{d\theta} = \frac{1}{F(\theta)} \cdot \frac{dF(\theta)}{d\theta} \rightarrow \text{regra da cadeia}$$

$$\text{Se } \frac{dF(\theta)}{d\theta} = 0 \Leftrightarrow \frac{d \ln F(\theta)}{d\theta} = 0$$

isso vendo que $\frac{1}{F(\theta)}$ não pode ser igual a zero dada a natureza da questão (σ^2 deveria ser 0, logo a gaussiana não teria um ponto máximo). Prosseguindo:

$$\ln F(\theta) = \ln \prod_{i=1}^n P(x_i | \theta)$$

Outros benefícios do $\ln$ será a simplificação do produto, seguindo as propriedades do logaritmo.

- $\ln(a \cdot b) = \ln(a) + \ln(b)$
- $\ln(a^b) = b \ln a$
- $\ln(e^x) = x$

Fun fact: $F(\theta)$ trabalha com números muito pequenos, pois são probabilidades que todos os n somados darão 1, logo são menores que 1 (ex: 0,00001). Com o $\ln$ esses números pequenas números negativos que são mais fáceis de serem manipulados (ex: $(-5) + (-10) \dots$).

Antes: Produto números muito pequenos
 $\Rightarrow$ máximo de zero
 $\Rightarrow$ underflow possível

Depois: Somatório números grandes
mais fácil de manipular

Continuando:

$$\ln F(\theta) = \sum_{i=1}^n \left[\ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \right) \right]$$

$$\ln F(\theta) = \sum_{i=1}^n \left[\underbrace{\ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)}_{\text{Termo 1}} + \underbrace{\left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right)}_{\text{Termo 2}} \right]$$

$$\text{Termo 1: } \ln \left((2\pi\sigma^2)^{-\frac{1}{2}} \right) = -\frac{1}{2} \ln(2\pi\sigma^2)$$

$\Rightarrow$ Somatório repete isso n vezes

$$\Rightarrow -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2)$$

Termo 2: $\sum_{i=1}^n \frac{-(x_i - \mu)^2}{2\sigma^2} = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$

$\Rightarrow \ln F(\theta) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2)$

$-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$

Utilizando gradiente para achar o máximo em relação a cada variável:

$\frac{\partial \ln F}{\partial \mu} = 0$

$\frac{\partial}{\partial \mu} \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right] = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0$

$\sum_{i=1}^n x_i - \sum_{i=1}^n \mu = 0 \Rightarrow \sum_{i=1}^n x_i - \mu n = 0$

$\Rightarrow \mu = \frac{1}{n} \sum_{i=1}^n x_i$ fórmula média

O estimador da máxima verossimilhança para a média é a própria média aritmética

Agora gradiente com variância:

$\frac{\partial \ln F}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0$

multiplicando tudo por $2(\sigma^2)^2$:

$-n\sigma^2 + \sum_{i=1}^n (x_i - \mu)^2 = 0$

$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$ fórmula variância

A variância que melhor explica os dados é a média dos desvios quadrados.

máx $(\nabla \ln F) = \begin{bmatrix} \text{fórmula média} \\ \text{fórmula variância} \end{bmatrix}$

$\frac{\partial}{\partial \sum_{i=1}^n (x_i - \mu)^2} \cdot \frac{\partial \sum_{i=1}^n (x_i - \mu)^2}{\partial \mu} \cdot \frac{\partial \sum_{i=1}^n (x_i - \mu)^2}{\partial \mu}$

$= -\frac{1}{2\sigma^2} \cdot 2 \sum_{i=1}^n (x_i - \mu) \cdot -1$

$= \frac{2 \sum_{i=1}^n (x_i - \mu)}{2\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu)$

$V = \sigma^2$

$\frac{\partial \ln F}{\partial V} = \frac{\partial}{\partial V} \left(-\frac{n}{2} \right) \ln V + \frac{\partial}{\partial V} \left(-\frac{1}{2V} \sum_{i=1}^n (x_i - \mu)^2 \right)$
 $= -\frac{n}{2} \cdot \frac{1}{V} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2} \cdot \frac{\partial}{\partial V} \left(-\frac{1}{V} \right)$
 $= -\frac{n}{2V} + \frac{1}{2V^2} \sum_{i=1}^n (x_i - \mu)^2$

$\frac{\partial \ln F}{\partial V} = -\frac{n}{2V} + \frac{1}{2V^2} \sum_{i=1}^n (x_i - \mu)^2$