

Instituto Federal do Ceará

Mestrado em Ciência da Computação

Disciplina: Reconhecimento de Padrões

Classificadores Bayesianos

Trabalho 02: Gaussiano Multivariado

Raquel Maciel Coelho de Sousa

Professor: Dr. Ajalmar Rocha Neto

Fortaleza, 11 de maio de 2026

Sumário

1	Introdução	2
2	Fundamentação Teórica	2
2.1	Teorema de Bayes	2
2.2	Distribuição Gaussiana Multivariada	2
2.3	Matriz de Covariância	2
2.4	Regularização de Tikhonov	3
2.5	Classificadores de Referência	3
2.6	Escolha do Par de Atributos para Visualização	3
3	Conjuntos de Dados	3
3.1	Flor Íris	3
3.2	Coluna Vertebral	3
3.3	Breast Cancer Wisconsin	3
3.4	Dermatology	4
3.5	Artificial I	4
4	Metodologia	4
5	Resultados e Discussão	4
5.1	Acurácia Média e Desvio Padrão	4
5.2	Matrizes de Confusão	5
5.3	Superfícies de Decisão	7
5.4	Discussão	9
6	Conclusão	9

1 Introdução

Este relatório descreve a implementação e avaliação do **Classificador Bayesiano Gaussiano Multivariado**, desenvolvido como Trabalho 02 da disciplina de Reconhecimento de Padrões. O modelo foi treinado e testado sobre cinco conjuntos de dados: Flor Íris, Coluna Vertebral, Breast Cancer Wisconsin, Dermatology e Artificial I, e seus resultados foram comparados com os classificadores KNN e DMC.

2 Fundamentação Teórica

2.1 Teorema de Bayes

O classificador fundamenta-se no Teorema de Bayes:

$$P(C_i | \mathbf{x}) = \frac{p(\mathbf{x} | C_i) P(C_i)}{p(\mathbf{x})} \quad (1)$$

onde $P(C_i)$ é a probabilidade *a priori* da classe, $p(\mathbf{x} | C_i)$ é a verossimilhança e $p(\mathbf{x}) = \sum_k p(\mathbf{x} | C_k) P(C_k)$ é a evidência. A decisão final é $\hat{C} = \arg \max_{C_i} P(C_i | \mathbf{x})$.

2.2 Distribuição Gaussiana Multivariada

A verossimilhança é modelada pela gaussiana multivariada de dimensão d :

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\} \quad (2)$$

onde $\boldsymbol{\mu}_i$ e Σ_i são estimados **independentemente para cada classe** a partir dos dados de treino, sem simplificações.

2.3 Matriz de Covariância

$$\Sigma = \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} & \cdots & \sigma_{1d} \\ \sigma_{21} & \sigma_{22}^2 & \cdots & \sigma_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1} & \sigma_{d2} & \cdots & \sigma_{dd}^2 \end{bmatrix} \quad (3)$$

A diagonal contém as variâncias individuais; fora da diagonal estão as covariâncias, que capturam correlações entre pares de atributos. A simetria ($\Sigma_{ij} = \Sigma_{ji}$) é explorada para reduzir cálculos: apenas o triângulo superior é computado.

2.4 Regularização de Tikhonov

Quando um atributo tem variância zero dentro de uma classe (comum em datasets com atributos binários e classes pequenas), Σ torna-se singular e não possui inversa. A solução adotada é somar $\epsilon \mathbf{I}$ à diagonal antes de inverter:

$$\Sigma_{\text{reg}} = \Sigma + \epsilon \mathbf{I}, \quad \epsilon = 10^{-6} \quad (4)$$

2.5 Classificadores de Referência

DMC — no treino calcula o centroide de cada classe $c_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$; na classificação escolhe a classe de menor distância euclidiana.

KNN ($k = 5$) — não possui treino explícito; classifica pelo voto majoritário entre os k vizinhos mais próximos no conjunto de treino.

2.6 Escolha do Par de Atributos para Visualização

O par foi selecionado maximizando o critério de Fisher :

$$\text{score}(a_1, a_2) = \text{Fisher}(a_1) + \text{Fisher}(a_2) \quad (5)$$

onde $\text{Fisher}(a) = \frac{\text{Var}(\mu_1, \dots, \mu_K)}{\text{média}(\sigma_1^2, \dots, \sigma_K^2)}$ mede o quanto as classes se afastam em relação ao seu espalhamento interno.

3 Conjuntos de Dados

3.1 Flor Íris

150 amostras, 4 atributos contínuos, 3 classes balanceadas. Dataset limpo, sem valores faltantes.

3.2 Coluna Vertebral

310 amostras, 6 atributos biomecânicos contínuos, 3 classes ortopédicas. Completamente numérico.

3.3 Breast Cancer Wisconsin

569 amostras, 30 atributos numéricos extraídos de imagens digitais, 2 classes. Foi utilizada a versão *Diagnostic* (UCI id=17), completamente numérica. A versão original (id=14) foi descartada por conter atributos categóricos que exigiriam imputação complexa.

3.4 Dermatology

366 amostras, 34 atributos, 6 classes. Valores faltantes foram imputados pela média da coluna.

3.5 Artificial I

Dataset sintético gerado com 3 classes gaussianas 2D ($n = 50$ por classe, semente 42):

- **Círculo:** $\mu = (1.0, 4.0), \sigma = 0.5$
- **Triângulo:** $\mu = (4.0, 4.0), \sigma = 0.5$
- **Estrela:** $\mu = (2.0, 2.0), \sigma = 0.5$

4 Metodologia

Foram realizadas **25 realizações** independentes por dataset. Em cada realização os dados foram embaralhados e divididos em 80% treino e 20% teste. Os quatro classificadores foram avaliados sobre a mesma divisão. Ao final:

$$\bar{A} = \frac{1}{N} \sum_{n=1}^N A_n \quad \sigma_A = \sqrt{\frac{1}{N} \sum_{n=1}^N (A_n - \bar{A})^2} \quad (6)$$

A matriz de confusão foi extraída da realização com acurácia **mais próxima da média**, por ser a mais representativa.

5 Resultados e Discussão

5.1 Acurácia Média e Desvio Padrão

Tabela 1: Resultados experimentais — 25 realizações, divisão 80/20.

Base de Dados	Bayesiano	KNN ($k = 5$)	DMC
Íris	97.5 ± 3.0	96.3 ± 2.9	90.9 ± 4.9
Artificial I	99.2 ± 1.4	99.2 ± 1.7	99.2 ± 1.4
Coluna Vertebral	83.9 ± 4.5	82.3 ± 3.3	75.7 ± 5.5
Breast Cancer	88.4 ± 3.0	93.6 ± 2.2	87.9 ± 2.7
Dermatology	88.6 ± 3.8	86.2 ± 2.9	50.4 ± 6.2

5.2 Matrizes de Confusão

Matriz de confusão de cada dataset com o classificador Bayesiano Multivariado. Buscando a melhor representatividade, foram utilizadas os registros da realização com a taxa de acerto mais próxima da acurácia para montar cada matriz.




Figura 1: Matriz de confusão — Íris.




Figura 2: Matriz de confusão — Vertebral Column.




Figura 3: Matriz de confusão — Breast Cancer.




Figura 4: Matriz de confusão — Dermatology.




Figura 5: Matrix de confusão — Artificial I.

5.3 Superfícies de Decisão

Superfícies de decisão do Bayesiano Multivariado com gaussianas sobrepostas. Treino (●), teste (×).




Figura 6: Superfície de decisão — Íris




Figura 7: Superfície de decisão — Artificial I




Figura 8: Superfície de decisão — Vertebral Column.

5.4 Discussão

O **Artificial I** atingiu acurácia próxima de 100% em todos os classificadores, confirmando que classes gaussianas bem separadas representam o cenário ideal para modelos probabilísticos.

Na **Íris**, o Bayesiano Multivariado (97.5%) supera o DMC (90.9%) e iguala o KNN (96.3%), beneficiando-se da modelagem das correlações entre atributos via Σ_i .

No **Breast Cancer**, o KNN (93.6%) supera o Bayesiano Multivariado (88.4%). Isso sugere que, com 30 atributos, a estimativa da matriz de covariância 30×30 a partir de apenas ~ 455 amostras de treino introduz ruído prejudicial — um fenômeno conhecido como *curse of dimensionality*.

No **Dermatology**, o DMC apresenta queda expressiva (50.4%), evidenciando que centroides são insuficientes para separar 6 classes com distribuições complexas. O Bayesiano Multivariado (88.6%) destaca-se como o melhor classificador neste dataset.

6 Conclusão

O Bayesiano Gaussiano Multivariado mostrou-se competitivo em todos os datasets, destacando-se especialmente no Dermatology. Sua principal limitação aparece em alta dimensionalidade (Breast Cancer), onde a estimativa de Σ torna-se instável. Os desafios práticos encontrados foram:

- **Overflow no expoente:** resolvido com *clipping* ao intervalo $[-500, 500]$;
- **Matriz singular:** resolvido com regularização de Tikhonov ($\varepsilon = 10^{-6}$);
- **Divisão treino/teste:** garantido mínimo de 1 amostra de teste por realização.

Referências

- [1] DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification**. 2. ed. Wiley-Interscience, 2001.
- [2] BISHOP, C. M. **Pattern Recognition and Machine Learning**. Springer, 2006.
- [3] DUA, D.; GRAFF, C. UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/ml>. Acesso em: 12 de maio de 2026.