

Instituto Federal do Ceará

Mestrado em Ciência da Computação

Disciplina: Reconhecimento de Padrões

Classificadores Bayesianos

Trabalho 03: Naive Bayes

Raquel Maciel Coelho de Sousa

Professor: Dr. Ajalmar Rocha Neto

Fortaleza, 11 de maio de 2026

Sumário

1	Introdução	2
2	Fundamentação Teórica	2
2.1	Teorema de Bayes	2
2.2	Pressuposto de Independência	2
2.3	Gaussiana Univariada por Atributo	2
2.4	Comparação com o Bayesiano Multivariado	3
2.5	Classificadores de Referência	3
2.6	Escolha do Par de Atributos para Visualização	3
3	Conjuntos de Dados	3
3.1	Flor Íris	3
3.2	Coluna Vertebral	4
3.3	Breast Cancer Wisconsin	4
3.4	Dermatology	4
3.5	Artificial I	4
4	Metodologia	4
5	Resultados e Discussão	4
5.1	Acurácia Média e Desvio Padrão	5
5.2	Matrizes de Confusão	5
5.3	Superfícies de Decisão	7
5.4	Discussão	9
6	Conclusão	10

1 Introdução

Este relatório descreve a implementação e avaliação do **Classificador Naive Bayes Gaussiano**, desenvolvido como complementação ao Trabalho 02 da disciplina de Reconhecimento de Padrões. Diferentemente do Bayesiano Multivariado, o Naive Bayes assume **independência condicional** entre os atributos dado a classe, simplificando o cálculo da verossimilhança.

O modelo foi treinado e testado sobre os mesmos cinco conjuntos de dados: Flor Íris, Coluna Vertebral, Breast Cancer Wisconsin, Dermatology e Artificial I, e seus resultados foram comparados com o Bayesiano Multivariado, KNN e DMC.

2 Fundamentação Teórica

2.1 Teorema de Bayes

O ponto de partida é o mesmo dos demais classificadores:

$$P(C_i | \mathbf{x}) = \frac{p(\mathbf{x} | C_i) P(C_i)}{p(\mathbf{x})} \quad (1)$$

onde $P(C_i)$ é a probabilidade *a priori*, $p(\mathbf{x} | C_i)$ é a verossimilhança e $p(\mathbf{x})$ é a evidência normalizadora.

2.2 Pressuposto de Independência

A diferença fundamental do Naive Bayes está na modelagem da verossimilhança. Assumindo que os atributos são **condicionalmente independentes** dado a classe C_i :

$$p(\mathbf{x} | C_i) = \prod_{j=1}^d p(x_j | C_i) \quad (2)$$

Ou seja, a verossimilhança conjunta é o **produto** das verossimilhanças individuais de cada atributo. Isso elimina a necessidade de estimar a matriz de covariância — cada atributo é modelado por uma gaussiana univariada independente.

2.3 Gaussiana Univariada por Atributo

Cada fator $p(x_j | C_i)$ é modelado por uma gaussiana 1D:

$$p(x_j | C_i) = \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} \exp\left\{-\frac{(x_j - \mu_{ij})^2}{2\sigma_{ij}^2}\right\} \quad (3)$$

onde μ_{ij} e σ_{ij}^2 são a média e a variância do atributo j na classe C_i , estimadas diretamente dos dados de treino. A posteriori final combina todos os atributos:

$$P(C_i | \mathbf{x}) \propto P(C_i) \prod_{j=1}^d \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} \exp\left\{-\frac{(x_j - \mu_{ij})^2}{2\sigma_{ij}^2}\right\} \quad (4)$$

2.4 Comparação com o Bayesiano Multivariado

A tabela abaixo resume as diferenças estruturais entre os dois modelos:

Tabela 1: Naive Bayes vs. Bayesiano Multivariado.

Aspecto	Naive Bayes	Multivariado
Verossimilhança	Produto de gaussianas 1D	Gaussiana d -dimensional
Parâmetros por classe	$2d$ (pois μ_j, σ_j^2)	$\approx \frac{d^2}{2}$ (pois μ, Σ)
Correlações	Ignoradas	Capturadas em Σ
Singularidade	Não ocorre	Possível (regularização)
Custo computacional	Baixo	Alto (inversão de Σ)

2.5 Classificadores de Referência

DMC — classifica pelo centroide mais próximo em distância euclidiana: $\hat{C} = \arg \min_{C_i} \|\mathbf{x} - \mathbf{c}_i\|_2$.

KNN ($k = 5$) — voto majoritário entre os k vizinhos mais próximos no conjunto de treino.

2.6 Escolha do Par de Atributos para Visualização

O par foi selecionado pelo critério de Fisher:

$$\text{score}(a_1, a_2) = \text{Fisher}(a_1) + \text{Fisher}(a_2) \quad (5)$$

3 Conjuntos de Dados

3.1 Flor Íris

150 amostras, 4 atributos contínuos, 3 classes balanceadas. Dataset limpo, sem valores faltantes.

3.2 Coluna Vertebral

310 amostras, 6 atributos biomecânicos contínuos, 3 classes ortopédicas. Completamente numérico.

3.3 Breast Cancer Wisconsin

569 amostras, 30 atributos numéricos, 2 classes. Versão *Diagnostic* (UCI id=17).

3.4 Dermatology

366 amostras, 34 atributos, 6 classes. Valores faltantes imputados pela média.

3.5 Artificial I

Dataset sintético gerado com 3 classes gaussianas 2D ($n = 50$ por classe, semente 42):

- **Círculo:** $\mu = (1.0, 4.0), \sigma = 0.5$
- **Triângulo:** $\mu = (4.0, 4.0), \sigma = 0.5$
- **Estrela:** $\mu = (2.0, 2.0), \sigma = 0.5$

4 Metodologia

Foram realizadas **25 realizações** independentes por dataset, com divisão 80% treino e 20% teste. A matriz de confusão foi extraída da realização com acurácia **mais próxima da média**. As superfícies de decisão foram geradas pelo Naive Bayes sobre o par de atributos selecionado pelo critério de Fisher.

5 Resultados e Discussão

5.1 Acurácia Média e Desvio Padrão

Tabela 2: Resultados experimentais — 25 realizações, divisão 80/20.

Base de Dados	Naive Bayes	Bayesiano	KNN ($k = 5$)	DMC
Íris	94.8 ± 4.3	97.5 ± 3.0	96.3 ± 2.9	90.9 ± 4.9
Artificial I	99.5 ± 1.2	99.2 ± 1.4	99.2 ± 1.7	99.2 ± 1.4
Coluna Vertebral	83.0 ± 4.4	83.9 ± 4.5	82.3 ± 3.3	75.7 ± 5.5
Breast Cancer	93.8 ± 1.9	88.4 ± 3.0	93.6 ± 2.2	87.9 ± 2.7
Dermatology	84.9 ± 4.4	88.6 ± 3.8	86.2 ± 2.9	50.4 ± 6.2

5.2 Matrizes de Confusão

Matriz de confusão de cada dataset com o classificador Naive Bayes. Buscando a melhor representatividade, foram utilizados os registros da realização com a taxa de acerto mais próxima da acurácia para montar cada matriz.




Figura 1: Matriz de confusão — Íris.




Figura 2: Matriz de confusão — Vertebral Column.




Figura 3: Matriz de confusão — Breast Cancer.




Figura 4: Matrix de confusão — Artificial I.

5.3 Superfícies de Decisão

Superfícies de decisão do Naive Bayes com gaussianas univariadas sobrepostas. Treino (●), teste (×).




Figura 5: Superfície de decisão — Íris




Figura 6: Superfície de decisão — Artificial I




Figura 7: Superfície de decisão — Vertebral Column.

5.4 Discussão

O **Naive Bayes** demonstrou desempenho surpreendentemente competitivo dada sua simplicidade. Seu destaque foi o **Breast Cancer** (93.8%), onde superou o Bayesiano Multivariado (88.4%). Isso ocorre porque, com 30 atributos e ~ 455 amostras de treino, a estimativa da matriz de covariância 30×30 é ruidosa — o pressuposto de independência do Naive Bayes evita esse problema ao custo de ignorar correlações.

No **Artificial I** (99.5%), o Naive Bayes apresentou o melhor resultado absoluto: como as classes foram geradas com covariância isotrópica (desvio padrão igual em ambas as direções), a ausência de correlações entre atributos é exatamente satisfeita — o pressuposto de independência é válido neste caso.

Na **Íris** (94.8%), o Naive Bayes fica ligeiramente abaixo do Bayesiano Multivariado (97.5%) e do KNN (96.3%), pois os atributos da pétala são correlacionados entre classes e essa informação é ignorada.

No **Dermatology** (84.9%), o Bayesiano Multivariado (88.6%) leva vantagem por capturar a estrutura conjunta das 6 classes. O DMC colapsa para 50.4%, evidenciando que centroides únicos não capturam a complexidade desse dataset.

6 Conclusão

O Naive Bayes mostrou-se uma escolha eficaz e eficiente, especialmente em alta dimensionalidade (Breast Cancer) onde o Bayesiano Multivariado sofre com estimativas ruidosas da matriz de covariância. O pressuposto de independência, embora raramente verdadeiro, produz fronteiras de decisão robustas na prática.

Comparado aos demais: supera o DMC em todos os datasets; equipara-se ao KNN; perde para o Bayesiano Multivariado quando as correlações entre atributos são informativas (Íris, Dermatology). Sua principal vantagem é o custo computacional reduzido — estima $2d$ parâmetros por classe contra $\approx d^2/2$ do Multivariado.

Referências

- [1] DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification**. 2. ed. Wiley-Interscience, 2001.
- [2] BISHOP, C. M. **Pattern Recognition and Machine Learning**. Springer, 2006.
- [3] DUA, D.; GRAFF, C. UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/ml>. Acesso em: 12 de maio de 2026.