

Instituto Federal do Ceará

Mestrado em Ciência da Computação

Disciplina: Reconhecimento de Padrões

Classificadores Bayesianos

Trabalho 04: Discriminantes Linear e Quadrático

Raquel Maciel Coelho de Sousa

Professor: Dr. Ajalmar Rocha Neto

Fortaleza, 18 de maio de 2026

Sumário

1	Introdução	2
2	Fundamentação Teórica	2
2.1	Classificador Bayesiano Gaussiano e o QDA	2
2.2	Superfície de Decisão Linear (LDA) — $\Sigma_i = \Sigma$	3
2.3	Caso Especial (Distância Mínima Euclidiana) — $\Sigma = \sigma^2 I$	6
2.4	Resumo: Quatro Situações da Matriz de Covariância	7
2.5	Classificadores de Referência	8
2.6	Escolha do Par de Atributos para Visualização	8
3	Conjuntos de Dados	9
3.1	Flor Íris	9
3.2	Coluna Vertebral	9
3.3	Breast Cancer Wisconsin	9
3.4	Dermatology	9
3.5	Artificial I	9
4	Metodologia	9
5	Resultados e Discussão	10
5.1	Acurácia Média e Desvio Padrão	10
5.2	Matrizes de Confusão	10
5.3	Superfícies de Decisão	13
5.4	Discussão	17
5.4.1	QDA completo vs. QDA diagonal	17
5.4.2	LDA <i>pooled</i> vs. LDA esférico	17
5.4.3	LDA vs. QDA	17
5.4.4	Comparação com trabalhos anteriores	17
6	Conclusão	17

1 Introdução

Este relatório descreve a implementação e avaliação do **Classificador Bayesiano Gaussiano** com base nos **discriminantes linear (LDA)** e **quadrático (QDA)**, desenvolvido como Trabalho 04 da disciplina de Reconhecimento de Padrões.

Diferentemente dos trabalhos anteriores, aqui a fronteira de decisão é derivada diretamente das funções discriminantes log-posteriori, permitindo verificar quatro situações distintas para a matriz de covariância: QDA com matriz completa por classe, QDA com matriz diagonal por classe, LDA com matriz *pooled* compartilhada e LDA com matriz esférica $\Sigma = \sigma^2 I$.

O modelo foi treinado e testado sobre os cinco conjuntos de dados: Flor Íris, Coluna Vertebral, Breast Cancer Wisconsin, Dermatology e Artificial I, e seus resultados foram comparados com os classificadores previamente implementados (Bayesiano Gaussiano Multivariado, Naive Bayes, KNN e DMC).

2 Fundamentação Teórica

2.1 Classificador Bayesiano Gaussiano e o QDA

O classificador Bayesiano ótimo tem como objetivo atribuir uma amostra de teste $\mathbf{x}$ à classe W_i que apresentar a maior probabilidade *a posteriori* $P(W_i | \mathbf{x})$. Pelo Teorema de Bayes, essa probabilidade é proporcional ao produto da verossimilhança pela probabilidade a priori: $P(W_i | \mathbf{x}) \propto p(\mathbf{x} | W_i) P(W_i)$.

Quando assumimos que os dados de cada classe seguem uma distribuição Gaussiana (Normal) multivariada, a equação envolve exponenciais. Para simplificar as contas matematicamente, aplicamos o logaritmo natural ($\ln$), que é uma função monotonicamente crescente e não altera qual classe terá o valor máximo. Assim, a nossa **função discriminante** básica passa a ser:

$$g_i(\mathbf{x}) = \ln p(\mathbf{x} | W_i) + \ln P(W_i) \quad (1)$$

Entendendo as Variáveis Base:

- $\mathbf{x}$: É o **vetor coluna** das características da amostra. Tem formato $d \times 1$, onde d é o número de atributos (dimensões) do problema.
- $P(W_i)$: É a **probabilidade a priori** da classe W_i . É um valor **escalar** (1×1) que reflete o nosso conhecimento prévio sobre a frequência da classe antes de olharmos para os dados.

Passo 1: Inserindo a Gaussiana Multivariada

Expandindo a Eq. (1) ao substituir a verossimilhança $p(\mathbf{x} | W_i)$ pela fórmula matemática da gaussiana d -dimensional $\mathcal{N}(\boldsymbol{\mu}_i, \Sigma_i)$, o logaritmo cancela a exponencial e chegamos à equação:

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) + \ln P(W_i) + c_i \quad (2)$$

Entendendo os Parâmetros Gaussianos:

- $\boldsymbol{\mu}_i$: É o **vetor de médias** da classe W_i . Formato: **vetor coluna** $d \times 1$.
- Σ_i : É a **matriz de covariância** da classe W_i . Formato: **matriz quadrada** $d \times d$. Ela modela o grau de espalhamento dos dados e a correlação entre os diferentes atributos daquela classe específica.
- Σ_i^{-1} : É a **matriz inversa** da covariância ($d \times d$).
- $(\mathbf{x} - \boldsymbol{\mu}_i)^T$: O sobrescrito T indica a **transposição**, transformando o vetor coluna num **vetor linha** $1 \times d$.
- *A Mágica da Álgebra*: O termo $(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)$ representa a multiplicação de um *vetor linha* ($1 \times d$), por uma *matriz* ($d \times d$), por um *vetor coluna* ($d \times 1$). O resultado dessa multiplicação em cadeia é um **único número (escalar)** 1×1 . Isso é fundamental, pois $g_i(\mathbf{x})$ precisa retornar uma pontuação única (escalar) para classificar a amostra.
- c_i : É uma constante normalizadora **escalar**, dada por $-\frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i|$, onde $|\Sigma_i|$ é o determinante da matriz.

Este é o modelo geral do **Discriminante Quadrático (QDA)**. Como cada classe possui a sua própria matriz de covariância (Σ_i), a superfície de decisão geométrica que separa as classes no espaço será curvilínea (uma quádriga, como uma elipse, parábola ou hipérbole).

Passo 2: Expansão Matricial

Aplicando a propriedade distributiva na Eq. (2), abrimos os parênteses do termo quadrático:

$$g_i(\mathbf{x}) = \underbrace{-\frac{1}{2}\mathbf{x}^T \Sigma_i^{-1} \mathbf{x}}_{\text{Termo Quadrático}} + \underbrace{\frac{1}{2}\mathbf{x}^T \Sigma_i^{-1} \boldsymbol{\mu}_i + \frac{1}{2}\boldsymbol{\mu}_i^T \Sigma_i^{-1} \mathbf{x}}_{\text{Termos Lineares dependentes de } \mathbf{x}} - \underbrace{\frac{1}{2}\boldsymbol{\mu}_i^T \Sigma_i^{-1} \boldsymbol{\mu}_i + \ln P(W_i) + c_i}_{\text{Termos Constantes}} \quad (3)$$

2.2 Superfície de Decisão Linear (LDA) — $\Sigma_i = \Sigma$

O LDA (**Análise Discriminante Linear**) é uma simplificação estratégica do modelo anterior. O que acontece se assumirmos que a dispersão dos dados é idêntica em todas as classes? Nesse caso, a matriz de covariância torna-se compartilhada (pooled): $\Sigma_i = \Sigma$.

Ao fazer isso, o termo puramente quadrático da equação anterior ($-\frac{1}{2}\mathbf{x}^T \Sigma^{-1} \mathbf{x}$) e a constante c_i passam a ser matematicamente iguais para todas as funções $g_i(\mathbf{x})$. Como o objetivo do classificador é apenas verificar qual $g_i(\mathbf{x})$ é maior, termos idênticos em todas as equações podem ser cancelados. Assim, o discriminante **perde a sua parte quadrática** e se reduz a:

$$g_i(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_i + \frac{1}{2}\boldsymbol{\mu}_i^T \Sigma^{-1} \mathbf{x} - \frac{1}{2}\boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i + \ln P(W_i) \quad (4)$$

Aprofundamento Didático: Visualizando os Elementos da Matriz

Para eliminar qualquer abstração geométrica, vamos abrir vetores e matrizes para visualizar o que compõe os termos da equação, como o $\boldsymbol{\mu}_i^T \Sigma_i^{-1} \mathbf{x}$. Considerando um conjunto de dados com d atributos, nós temos:

- $\mathbf{x}$ é o vetor coluna de características da amostra: $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$
- $\boldsymbol{\mu}_i$ é o vetor coluna de médias da classe W_i . Sua forma transposta $\boldsymbol{\mu}_i^T$ vira um vetor linha: $\boldsymbol{\mu}_i^T = [\mu_{i1} \ \mu_{i2} \ \dots \ \mu_{id}]$
- Σ_i^{-1} é a matriz inversa de covariância (vamos chamar seus elementos de s_{jk}):

$$\Sigma_i^{-1} = \begin{bmatrix} s_{11} & s_{12} & \dots & s_{1d} \\ s_{21} & s_{22} & \dots & s_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ s_{d1} & s_{d2} & \dots & s_{dd} \end{bmatrix}$$

Ao montarmos a multiplicação do termo $\boldsymbol{\mu}_i^T \Sigma_i^{-1} \mathbf{x}$, ela fica literalmente assim:

$$\boldsymbol{\mu}_i^T \Sigma_i^{-1} \mathbf{x} = \underbrace{\begin{bmatrix} \mu_{i1} & \mu_{i2} & \dots & \mu_{id} \end{bmatrix}}_{\text{Vetor Linha } (1 \times d)} \underbrace{\begin{bmatrix} s_{11} & s_{12} & \dots & s_{1d} \\ s_{21} & s_{22} & \dots & s_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ s_{d1} & s_{d2} & \dots & s_{dd} \end{bmatrix}}_{\text{Matriz Quadrada } (d \times d)} \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}}_{\text{Vetor Coluna } (d \times 1)}$$

$$\boldsymbol{\mu}_i^T \Sigma_i^{-1} \mathbf{x} = \begin{bmatrix} \mu_{i1} & \mu_{i2} & \dots & \mu_{id} \end{bmatrix} \begin{bmatrix} s_{11} \cdot x_1 + s_{12} \cdot x_2 + \dots + s_{1d} \cdot x_d \\ s_{21} \cdot x_1 + s_{22} \cdot x_2 + \dots + s_{2d} \cdot x_d \\ \vdots \\ s_{d1} \cdot x_1 + s_{d2} \cdot x_2 + \dots + s_{dd} \cdot x_d \end{bmatrix}$$

$$\boldsymbol{\mu}_i^T \boldsymbol{\Sigma}_i^{-1} \mathbf{x} = \mu_{i1}(s_{11} \cdot x_1 + s_{12} \cdot x_2 + \dots + s_{1d} \cdot x_d) + \dots + \mu_{id}(s_{d1} \cdot x_1 + s_{d2} \cdot x_2 + \dots + s_{dd} \cdot x_d)$$

$$\boldsymbol{\mu}_i^T \boldsymbol{\Sigma}_i^{-1} \mathbf{x} = \sum_{n=1}^d \sum_{m=1}^d \mu_{in} \cdot s_{nm} \cdot x_m$$

Agora provar a equivalência com o termo $\mathbf{x}^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i$:

$$\begin{aligned} \mathbf{x}^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i &= \underbrace{\begin{bmatrix} x_1 & x_2 & \dots & x_d \end{bmatrix}}_{\text{Vetor Linha } (1 \times d)} \underbrace{\begin{bmatrix} s_{11} & s_{12} & \dots & s_{1d} \\ s_{21} & s_{22} & \dots & s_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ s_{d1} & s_{d2} & \dots & s_{dd} \end{bmatrix}}_{\text{Matriz Quadrada } (d \times d)} \underbrace{\begin{bmatrix} \mu_{i1} \\ \mu_{i2} \\ \vdots \\ \mu_{id} \end{bmatrix}}_{\text{Vetor Coluna } (d \times 1)} \\ \\ \mathbf{x}^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i &= \begin{bmatrix} x_1 & x_2 & \dots & x_d \end{bmatrix} \begin{bmatrix} s_{11} \cdot \mu_{i1} + s_{12} \cdot \mu_{i2} + \dots + s_{1d} \cdot \mu_{id} \\ s_{21} \cdot \mu_{i1} + s_{22} \cdot \mu_{i2} + \dots + s_{2d} \cdot \mu_{id} \\ \vdots \\ s_{d1} \cdot \mu_{i1} + s_{d2} \cdot \mu_{i2} + \dots + s_{dd} \cdot \mu_{id} \end{bmatrix} \end{aligned}$$

$$\mathbf{x}^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i = x_1(s_{11} \cdot \mu_{i1} + s_{12} \cdot \mu_{i2} + \dots + s_{1d} \cdot \mu_{id}) + \dots + x_d(s_{d1} \cdot \mu_{i1} + s_{d2} \cdot \mu_{i2} + \dots + s_{dd} \cdot \mu_{id})$$

$$\mathbf{x}^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i = \sum_{n=1}^d \sum_{m=1}^d x_n \cdot s_{nm} \cdot \mu_{im}$$

Para provarmos que a igualdade dos termos:

$$\mathbf{x}^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i = \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}_i^{-1} \mathbf{x}$$

$$\sum_{n=1}^d \sum_{m=1}^d x_n \cdot s_{nm} \cdot \mu_{im} = \sum_{n=1}^d \sum_{m=1}^d \mu_{in} \cdot s_{nm} \cdot x_m$$

$$\sum_{n=1}^d \sum_{m=1}^d x_n \cdot s_{nm} \cdot \mu_{im} = \sum_{n=1}^d \sum_{m=1}^d x_n \cdot s_{mn} \cdot \mu_{im}$$

Pela simetria de Σ podemos admitir que sua inversa também será simétrica.

$$\sum_{n=1}^d \sum_{m=1}^d x_n \cdot s_{nm} \cdot \mu_{im} = \sum_{n=1}^d \sum_{m=1}^d x_n \cdot s_{nm} \cdot \mu_{im}$$

É exatamente por isso que os dois termos centrais da Eq. (3) se somam ($0,5 + 0,5 = 1$), gerando a equação linear do LDA.

Para deixar essa equação enxuta, podemos agrupar os termos. Definimos um novo vetor de pesos $\mathbf{w}_i$ e uma constante de viés (*bias*) w_{i0} :

- $\mathbf{w}_i = \Sigma_i^{-1} \boldsymbol{\mu}_i$: Um **vetor coluna** ($d \times 1$) que define a orientação/inclinação da reta ou plano de decisão.
- $w_{i0} = \ln P(W_i) - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma_i^{-1} \boldsymbol{\mu}_i$: Um termo **escalar** de ajuste.

Substituindo essas novas variáveis, a equação vira uma função estritamente linear:

$$g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0} \quad (5)$$

O resultado geométrico prático do LDA é que a superfície de decisão $g_i(\mathbf{x}) = g_j(\mathbf{x})$ que separa duas classes vira uma linha perfeitamente reta (um **hiperplano**).

2.3 Caso Especial (Distância Mínima Euclidiana) — $\Sigma = \sigma^2 I$

Podemos realizar uma simplificação ainda mais forte. E se assumirmos que, além de compartilharem a matriz Σ , todos os atributos do nosso dataset são totalmente independentes entre si (descorrelacionados) e possuem exatamente a mesma variância (espalhamento)?.

Nesse caso extremo, a matriz de covariância compartilhada Σ vira simplesmente $\sigma^2 I$, onde I é a **Matriz Identidade** e σ^2 é a variância escalar. A equação do LDA se reduz para:

$$g_i(\mathbf{x}) = \frac{1}{\sigma^2} \boldsymbol{\mu}_i^T \mathbf{x} + w_{i0} \quad (6)$$

O hiperplano de decisão será:

$$g_{ij}(\mathbf{x}) \equiv g_i(\mathbf{x}) - g_j(\mathbf{x}) = 0$$

$$\frac{1}{\sigma^2} \boldsymbol{\mu}_i^T \mathbf{x} + w_{i0} - \frac{1}{\sigma^2} \boldsymbol{\mu}_j^T \mathbf{x} - w_{j0} = 0$$

$$\frac{1}{\sigma^2} \boldsymbol{\mu}_i^T \mathbf{x} + \ln P(W_i) - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i - \frac{1}{\sigma^2} \boldsymbol{\mu}_j^T \mathbf{x} - \ln P(W_j) + \frac{1}{2} \boldsymbol{\mu}_j^T \Sigma^{-1} \boldsymbol{\mu}_j = 0$$

$$\frac{1}{\sigma^2} \boldsymbol{\mu}_i^T \mathbf{x} - \frac{1}{\sigma^2} \boldsymbol{\mu}_j^T \mathbf{x} + \frac{1}{2\sigma^2} \boldsymbol{\mu}_j^T \boldsymbol{\mu}_j - \frac{1}{2\sigma^2} \boldsymbol{\mu}_i^T \boldsymbol{\mu}_i + \ln P(W_i) - \ln P(W_j) = 0$$

$$\frac{1}{\sigma^2} (\boldsymbol{\mu}_i^T \mathbf{x} - \boldsymbol{\mu}_j^T \mathbf{x}) + \frac{1}{2\sigma^2} (\boldsymbol{\mu}_j^T \boldsymbol{\mu}_j - \boldsymbol{\mu}_i^T \boldsymbol{\mu}_i) + \ln \left(\frac{P(W_i)}{P(W_j)} \right) = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \mathbf{x} + \frac{1}{2}(\boldsymbol{\mu}_j + \boldsymbol{\mu}_i)^T (\boldsymbol{\mu}_j - \boldsymbol{\mu}_i) + \sigma^2 \ln \left(\frac{P(W_i)}{P(W_j)} \right) = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \mathbf{x} - \frac{1}{2}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) + \sigma^2 \ln \left(\frac{P(W_i)}{P(W_j)} \right) \frac{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \left(\mathbf{x} - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) + \sigma^2 \ln \left(\frac{P(W_i)}{P(W_j)} \right) \frac{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} \right) = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \left(\mathbf{x} - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) + \sigma^2 \ln \left(\frac{P(W_i)}{P(W_j)} \right) \frac{\boldsymbol{\mu}_i - \boldsymbol{\mu}_j}{\|\boldsymbol{\mu}_i - \boldsymbol{\mu}_j\|^2} \right) = 0$$

Se as classes tiverem probabilidades a priori idênticas (equiprováveis), maximizar esse discriminante é exatamente o mesmo que classificar o padrão verificando qual vetor de média $\boldsymbol{\mu}_i$ está geograficamente mais perto dele, utilizando o cálculo convencional de **Distância Euclidiana**.

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \left(\mathbf{x} - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) + \sigma^2 \ln 1 \frac{\boldsymbol{\mu}_i - \boldsymbol{\mu}_j}{\|\boldsymbol{\mu}_i - \boldsymbol{\mu}_j\|^2} \right) = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \left(\mathbf{x} - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) \right) = 0$$

2.4 Resumo: Quatro Situações da Matriz de Covariância

A Tabela 1 consolida a evolução das equações demonstradas, mapeando as quatro variações de implementação solicitadas para o Trabalho 04 .

Tabela 1: Modos de covariância e a forma geométrica resultante no modelo.

Modo	Covariância	Equação	Fronteira Geométrica
QDA completo	Σ_i completa, individual por classe	Eq. (2)	Curva (Quádrica Livre)
QDA diagonal	Σ_i diagonal, individual por classe	Eq. (2)	Curva (Quádrica alinhada aos eixos)
LDA <i>pooled</i>	Σ completa, compartilhada por todos	Eq. (5)	Reta/Plano (Hiperplano)
LDA esférico	$\Sigma = \sigma^2 I$, compartilhada e isotrópica	Eq. (6)	Reta/Plano Ortogonal (Euclidiana)

2.5 Classificadores de Referência

Para fins de comparação neste relatório, testamos a nossa implementação baseada no discriminante contra outros modelos implementados anteriormente na disciplina:

- **Bayesiano Multivariado** — Baseia-se no mesmo fundamento do discriminante da Eq. (2), utilizando o cálculo probabilístico nativo.
- **Naive Bayes** — Assume total independência condicional entre os atributos; o cálculo da verossimilhança é o mero produtório de gaussianas unidimensionais (1D).
- **DMC (Distância Mínima ao Centróide)** — Funciona com base puramente geométrica, classificando o padrão pela menor distância Euclidiana:

$$\hat{C} = \arg \min_{C_i} \|\mathbf{x} - \mathbf{c}_i\|_2 \quad (7)$$

- **KNN ($k = 5$)** — Classificação baseada no voto majoritário dos k vizinhos geográficos mais próximos.

2.6 Escolha do Par de Atributos para Visualização

A escolha das duas melhores características (2D) para plotagem das superfícies de decisão foi baseada no **Crítério de Fisher**, que busca maximizar a variância entre as classes e minimizar a variância dentro delas:

$$\text{score}(a_1, a_2) = \text{Fisher}(a_1) + \text{Fisher}(a_2), \quad \text{Fisher}(a) = \frac{\text{variância entre classes}(a)}{\text{variância dentro das classes}(a)} \quad (8)$$

3 Conjuntos de Dados

3.1 Flor Íris

150 amostras, 4 atributos contínuos, 3 classes balanceadas (Setosa, Versicolor e Virginica). Dataset limpo, sem valores faltantes.

3.2 Coluna Vertebral

310 amostras, 6 atributos biomecânicos contínuos, 3 classes ortopédicas (Normal, Hérnia, Espondilolistese). Completamente numérico.

3.3 Breast Cancer Wisconsin

569 amostras, 30 atributos numéricos, 2 classes (Benigno e Maligno). Versão *Diagnostic* (UCI id=17).

3.4 Dermatology

366 amostras, 34 atributos, 6 classes de doenças dermatológicas. Valores faltantes imputados pela média da coluna.

3.5 Artificial I

Dataset sintético gerado com 3 classes gaussianas 2D ($n = 50$ por classe, semente 42):

- **Círculo:** $\mu = (1,0, 4,0), \sigma = 0,5$
- **Triângulo:** $\mu = (4,0, 4,0), \sigma = 0,5$
- **Estrela:** $\mu = (2,0, 2,0), \sigma = 0,5$

4 Metodologia

Foram realizadas **25 realizações** independentes por dataset, com divisão 80% treino e 20% teste (embaralhamento aleatório a cada realização). Para cada dataset foram executados os **oito classificadores**: Bayesiano Multivariado, Naive Bayes, DMC, KNN, QDA completo, QDA diagonal, LDA *pooled* e LDA esférico.

A matriz de confusão foi extraída da realização com acurácia **mais próxima da média** do QDA completo, por ser o classificador central deste trabalho. As superfícies

de decisão foram plotadas para o QDA completo e o LDA *pooled*, sobre o par de atributos selecionado pelo critério de Fisher, exibindo os dados de treino (●) e teste (×).

A matriz de covariância *pooled* foi estimada por:

$$\hat{\Sigma} = \frac{\sum_{i=1}^c (n_i - 1) \hat{\Sigma}_i}{N - c} \quad (9)$$

onde n_i é o número de amostras da classe i , N é o total de amostras de treino e c é o número de classes. Uma regularização ϵI ($\epsilon = 10^{-6}$) foi aplicada antes de inverter qualquer matriz de covariância, para evitar singularidades.

5 Resultados e Discussão

5.1 Acurácia Média e Desvio Padrão

Tabela 2: Resultados dos trabalhos anteriores — 25 realizações, divisão 80/20.

Base de Dados	Bayes. Mult.	Naive Bayes	KNN ($k=5$)	DMC
Íris	$97,3 \pm 3,3$	$95,9 \pm 2,9$	$97,0 \pm 1,9$	$92,2 \pm 4,8$
Artificial I	$99,6 \pm 1,1$	$99,5 \pm 1,2$	$99,4 \pm 1,2$	$99,6 \pm 1,0$
Coluna Vertebral	$84,8 \pm 3,7$	$84,6 \pm 3,2$	$82,3 \pm 3,5$	$77,8 \pm 4,0$
Breast Cancer	$88,2 \pm 2,7$	$93,7 \pm 2,2$	$92,9 \pm 2,2$	$89,0 \pm 2,4$
Dermatology	$88,0 \pm 3,5$	$84,8 \pm 3,8$	$86,7 \pm 3,7$	$49,7 \pm 3,6$

Tabela 3: Resultados do Trabalho 04 (LDA/QDA) — 25 realizações, divisão 80/20.

Base de Dados	QDA completo	QDA diagonal	LDA <i>pooled</i>	LDA esférico
Íris	$97,4 \pm 2,3$	$95,4 \pm 3,8$	$98,5 \pm 2,1$	$92,2 \pm 5,7$
Artificial I	$99,3 \pm 1,3$	$99,4 \pm 1,2$	$99,0 \pm 1,5$	$99,2 \pm 1,4$
Coluna Vertebral	$84,8 \pm 5,0$	$83,4 \pm 4,6$	$79,4 \pm 4,6$	$77,2 \pm 5,7$
Breast Cancer	$89,0 \pm 2,5$	$92,6 \pm 1,9$	$95,3 \pm 1,7$	$89,1 \pm 2,7$
Dermatology	$92,8 \pm 3,7$	$97,3 \pm 1,6$	$96,5 \pm 2,8$	$53,7 \pm 6,6$

5.2 Matrizes de Confusão

Matrizes de confusão geradas pelo QDA completo na realização com taxa de acerto mais próxima da média, por ser o classificador central deste trabalho.




Figura 1: Matriz de confusão — Íris (QDA completo).




Figura 2: Matriz de confusão — Vertebral Column (QDA completo).




Figura 3: Matriz de confusão — Breast Cancer (QDA completo).




Figura 4: Matriz de confusão — Dermatology (QDA completo).




Figura 5: Matriz de confusão — Artificial I (QDA completo).

5.3 Superfícies de Decisão

Superfícies de decisão comparando QDA completo (fronteira quádrlica) e LDA *pooled* (fronteira linear) para os datasets Artificial I, Íris e Coluna Vertebral, com dados de treino (●) e teste (×).




Figura 6: Superfície de decisão — Artificial I (QDA completo).




Figura 7: Superfície de decisão — Artificial I (LDA *pooled*).




Figura 8: Superfície de decisão — Íris (QDA completo).




Figura 9: Superfície de decisão — Íris (LDA *pooled*).




Figura 10: Superfície de decisão — Coluna Vertebral (QDA completo).




Figura 11: Superfície de decisão — Coluna Vertebral (LDA *pooled*).

5.4 Discussão

5.4.1 QDA completo vs. QDA diagonal

O QDA com matriz completa captura as correlações entre atributos de cada classe, modelando fronteiras elípticas orientadas livremente no espaço de características. O QDA diagonal assume que os atributos são condicionalmente independentes por classe (covariâncias cruzadas nulas), produzindo elipses com eixos alinhados aos atributos. Para datasets onde as correlações intraclasse são relevantes — como a Coluna Vertebral — espera-se que o QDA completo supere o diagonal. Nos datasets de baixa dimensionalidade como o Artificial I (gerado com covariância isotrópica), ambos devem apresentar desempenho similar.

5.4.2 LDA *pooled* vs. LDA esférico

O LDA *pooled* estima uma matriz de covariância única $\hat{\Sigma}$ a partir de todas as classes, preservando informações de espalhamento e correlação globais. O LDA esférico restringe ainda mais: $\Sigma = \sigma^2 I$, assumindo variâncias iguais e atributos descorrelacionados globalmente. Quando essa suposição é válida, ambos produzem fronteiras lineares de desempenho equivalente; quando não, o LDA *pooled* tem vantagem.

5.4.3 LDA vs. QDA

O LDA impõe a restrição de fronteira linear (hiperplano), o que reduz a variância do modelo mas aumenta o viés quando as classes realmente possuem covariâncias distintas. O QDA é mais flexível (fronteiras quádricas) e tende a superá-lo em datasets com classes de formas muito diferentes, porém requer a estimativa de c matrizes $d \times d$ separadas — o que pode ser ruidoso com poucas amostras por classe. No Breast Cancer ($d = 30$), por exemplo, espera-se que o LDA leve vantagem por evitar overfitting na estimativa de Σ_j .

5.4.4 Comparação com trabalhos anteriores

O Bayesiano Multivariado dos trabalhos anteriores é essencialmente o mesmo que o QDA completo aqui implementado (a diferença está apenas na forma de computar a classificação: *posteriori* explícita versus discriminante log-linear). Portanto, os resultados devem concordar numericamente para validar a implementação.

6 Conclusão

Os quatro modos de covariância implementados formam uma hierarquia de flexibilidade versus custo computacional/amostral: QDA completo > QDA diagonal >

LDA *pooled* > LDA esférico. O modelo mais adequado depende do dataset: em alta dimensionalidade com poucas amostras (Breast Cancer, Dermatology), modelos mais restritivos tendem a generalizar melhor; em baixa dimensionalidade com classes bem separadas (Artificial I), todos convertem para resultados similares.

A principal contribuição deste trabalho frente aos anteriores é a demonstração de que fronteiras lineares (LDA) são suficientes quando a hipótese de covariância compartilhada é razoável, representando um ganho direto em interpretabilidade e em custo de estimativa de parâmetros, sem perda significativa de acurácia em boa parte dos datasets avaliados.

Referências

- [1] DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification**. 2. ed. Wiley-Interscience, 2001.
- [2] BISHOP, C. M. **Pattern Recognition and Machine Learning**. Springer, 2006.
- [3] ROCHA NETO, A. **Densidade de Probabilidade Gaussiana** — Notas de Aula. PPGET/IFCE, 2013.
- [4] DUA, D.; GRAFF, C. UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/ml>. Acesso em: 18 de maio de 2026.